

Técnicas Avançadas em Aprendizagem por Máquinas

Bruno Tebaldi de Queriroz Barbosa

August 10, 2024

Table of Contents

Fundamentos

Regressão linear simples

Shrinkage Methods

Regressão Logística

Métricas de avaliação

K-Nearest Neighbors

Validação Cruzada

Table of Contents

Fundamentos

Introdução

Tipos de Variáveis

Tipos de Dados

Medidas Resumo

Medidas de posição

Medidas de dispersão

Transformações de dados

Log

Normalização

Max-Min

Box-Cox

One-to-Hot

Pivoting

Tipos de problemas

Introdução

- ▶ Bem vindo ao curso sobre Machine Learning!
- ▶ Este curso foi elaborado para fornecer uma introdução abrangente ao campo do aprendizado de máquina, com foco tanto nos fundamentos teóricos quanto nas aplicações práticas.

Objetivos

- ▶ O objetivo da aula de hoje é estabelecer as bases para a sua compreensão do aprendizado de máquina, abordando os seguintes tópicos principais:
 1. **Tipos de dados:** Compreender diferentes tipos de dados (categóricos, numéricos, texto e séries temporais) e sua importância no aprendizado de máquina.
 2. **Tipos de Problemas:** Identificar diferentes tipos de problemas de aprendizado de máquina (regressão, classificação, clustering, detecção de anomalias e sistemas de recomendação) e compreender suas características.
 3. **Classes de modelos:** Exploração de diversas classes de modelos de aprendizado de máquina (modelos lineares, modelos baseados em árvore, modelos baseados em instâncias, redes neurais e modelos de conjunto) e suas aplicações.


Tipos de Variáveis

- ▶ **Variáveis Qualitativas:** apresentam como possíveis realizações uma qualidade (ou atributo) do indivíduo pesquisado.
 - ▶ **Nominal:** A variável qualitativa pode ser nominal para a qual não existe nenhuma ordenação nas possíveis realizações.
 - ▶ **Ordinal:** A variável qualitativa pode ser ordinal para a qual existe uma certa ordem ou hierarquia nos possíveis resultados.

Tipos de Variáveis

- ▶ **Variáveis Quantitativas:** apresentam como possíveis realizações números resultantes de uma contagem ou mensuração.
 - ▶ **Discretas:** os valores formam um conjunto finito ou infinito enumerável de números e que resultam frequentemente de uma contagem (ex.: número de filhos).
 - ▶ **Contínuas:** os possíveis valores formam um intervalo de números reais (ex.: altura das pessoas, autonomia de um automóvel; temperatura de uma sala).

Tipos de Variáveis



Tipos de Dados

- ▶ Seção Transversal
 - ▶ Cada observação é um novo indivíduo, empresa, etc. com informações em um ponto no tempo.
 - ▶ A amostra é aleatória, um indivíduo não influencia em outro.
- ▶ Serie temporal
 - ▶ Cada observação é separada por um período de tempo
 - ▶ A amostra não é aleatória, existe dependência temporal.
 - ▶ Tendências e sazonalidade serão importantes!
- ▶ Painei
 - ▶ Os dados são agrupados em duas dimensões.
 - ▶ Uma dimensão representando indivíduos.
 - ▶ Uma dimensão representando uma serie temporal.

Medidas Resumo

Importância e Utilização

As **medidas resumo**, também conhecidas como estatísticas descritivas, são ferramentas essenciais para a análise de dados. Elas fornecem uma visão condensada e informativa dos principais aspectos de um conjunto de dados, ajudando a simplificar e interpretar grandes volumes de informações.

Medidas Resumo

Definições

Total de observações

O total de observações é o tamanho da amostra. Usaremos a notação n para indicar o total de observações.

Frequência Absoluta

A frequência absoluta de um evento é o número de vezes que o evento ocorreu em um experimento ou estudo. Usaremos a notação n_i para indicar a frequência de cada variável;

Proporção/Frequência relativa

A Proporção, também conhecida como frequência relativa, é a razão entre a frequência absoluta e o tamanho da amostra. Usaremos a notação f_i para indicar o total de observações.

$$f_i = \frac{n_i}{n}$$

Medidas Resumo

As medidas resumo mais utilizadas são:

- ▶ Medidas de tendência central;
 - ▶ Moda;
 - ▶ Média;
 - ▶ Mediana;
- ▶ Medidas de dispersão;
 - ▶ Percentis, quartis e decis
 - ▶ Variância populacional e amostral
 - ▶ Desvio padrão;
 - ▶ Valores mínimo e máximo

Moda

Medidas de posição

Moda

Moda é definida como a realização mais frequente do conjunto de valores observados.

- ▶ Em alguns casos, pode haver mais de uma moda, ou seja, a distribuição dos valores pode ser bimodal, trimodal, etc.

Moda

Medidas de posição

Example

No Filhos	n_i	$f_i = n_i/n$
0	4	0.20
1	5	0.25
2	7	0.35
3	3	0.15
5	1	0.05
Total	20	1

Considerando a variável número de filhos, vemos que a moda é 2, correspondente à realização com a maior frequência, 7.

Moda

Medidas de posição

R Exemplo

```
num_filhos <- c(rep(0,4),rep(1,5),rep(2,7),rep(3,3),rep(5,1))
tbl <- data.frame(num_filhos=data.raw) %>%
  group_by(num_filhos) %>%
  summarise(ni=n()) %>%
  mutate(fi = ni/sum(ni), perc = fi*100)

tbl
## A tibble: 5 x 4
#   num_filhos    ni    fi perc
#   <dbl> <int> <dbl> <dbl>
#1         0     4  0.2   20
#2         1     5  0.25  25
#3         2     7  0.35  35
#4         3     3  0.15  15
#5         5     1  0.05   5
tbl[which.max(tbl$fi), ]
## A tibble: 1 x 4
#   num_filhos    ni    fi perc
#   <dbl> <int> <dbl> <dbl>
#1         2     7  0.35  35
```

Média aritmética

Medidas de posição

Média aritmética

A média aritmética é a soma das observações dividida pelo número total de observações.

$$\bar{X} = \frac{1}{N} \sum_{i=1}^N x_i$$

- ▶ A média aritmética é a mais utilizada porém em algumas situações a mediana é um valor mais adequado. Isso se deve ao fato que a média é sensível a *outliers*.

Média aritmética

Medidas de posição

Example

No Filhos	n_i	$f_i = n_i/n$
0	4	0.20
1	5	0.25
2	7	0.35
3	3	0.15
5	1	0.05
Total	20	1

$$\bar{X} = \frac{(0 * 4) + (1 * 5) + (2 * 7) + (3 * 3) + (5 * 1)}{20}$$

$$\bar{X} = (0 * 0.20) + (1 * 0.25) + (2 * 0.35) + (3 * 0.15) + (5 * 0.05)$$

$$\bar{X} = 1.65$$

Média geométrica

Medidas de posição

Média geométrica

A média geométrica é definida como o produto de todos os membros do conjunto elevado ao inverso do número de membros.

$$\bar{G} = \sqrt[N]{\prod_{i=1}^N x_i}$$

- ▶ Note que a média geométrica deve admitir um conjunto de números não negativos.
- ▶ A média geométrica “zera” se um dos elementos for zero.

Média geométrica

Medidas de posição

Example

No Filhos	n_i	$f_i = n_i/n$
0	4	0.20
1	5	0.25
2	7	0.35
3	3	0.15
5	1	0.05
Total	20	1

$$\bar{G} = \sqrt[20]{0^4 \times 1^5 \times 2^7 \times 3^3 \times 5^1}$$

$$\bar{G} = 0$$

Média

Medidas de posição

R Exemplo

```
# Exemplo 1
num_filhos <- c(rep(0,4),rep(1,5),rep(2,7),rep(3,3),rep(5,1))
num_filhos
mean(num_filhos)
#[1] 1.65
geometric.mean <- prod(num_filhos)^(1/length(num_filhos))
geometric.mean
#[1] 0
# Exemplo 2
geometric.mean <- function(x, na.rm=TRUE){
  ret <- mean(log(x))
  return(exp(ret))
}
geometric.mean(num_filhos)
#[1] 0
geometric.mean(1:3)
#[1] 1.817121
```

Mediana

Medidas de posição

Mediana

A mediana é a realização que ocupa a posição central da série de observações quando esta ordenada.

- ▶ Quando o número de observações é par, usa-se como mediana a média aritmética das duas observações centrais. Assim, se as observações de uma variável são 3, 3, 7, 8, 8 e 9 a mediana é $\frac{7+8}{2} = 7,5$.

Mediana

Medidas de posição

Example

No Filhos	n_i	$f_i = n_i/n$
0	4	0.20
1	5	0.25
2	7	0.35
3	3	0.15
5	1	0.05
Total	20	1

$\underbrace{\{0, 0, 0, 0, 1, 1, 1, 1, 1, 1\}}_{10}, \underbrace{\{2, 2, 2, 2, 2, 2, 2, 3, 3, 3, 5\}}_{10}$

$$\text{Mediana} = \frac{2 + 2}{2} = 2$$

Mediana

Medidas de posição

R Exemplo

```
num_filhos <- c(rep(0,4),rep(1,5),rep(2,7),rep(3,3),rep(5,1))
num_filhos
# [1] 0 0 0 0 1 1 1 1 1 1 2 2 2 2 2 2 2 3 3 3 5
median(num_filhos)
# [1] 2
```

Quantil, Quartil, Decil, Percentil

Medidas de dispersão

Quantil (p-quantil)

O quantil de ordem p ou p-quantil, onde p é um número real maior que zero e menor que um ($0 \leq p \leq 1$), é o valor tal que $p \times 100\%$ das observações da amostra sejam menores que ele

Quantil, Quartil, Decil, Percentil

Medidas de dispersão

- ▶ O Quantil não é necessariamente um elemento pertencente à amostra
- ▶ Um caso especial do quantil é o Quartil que divide a amostra em quatro partes
 - ▶ O 25%-quantil é o primeiro Quartil (Q1);
 - ▶ O 50%-quantil é o segundo Quartil (Q2), conhecido como Mediana;
 - ▶ O 75%-quantil é o terceiro Quartil (Q3)

Quantil

Medidas de dispersão

R Exemplo

```
numeros <- c(1, 3, 5, 6, 9, 11, 12, 13, 19, 21)
quantile(numeros, probs = seq(0, 1, 0.25), type = 6)
# 0% 25% 50% 75% 100%
# 1.0 4.5 10.0 14.5 21.0
```

Variância populacional

Medidas de dispersão

Variância populacional

A variância é dada pela média do quadrado dos desvios de cada observação em relação a média populacional.

$$\mathbb{V}ar [X] = \sum_{i=1}^n \frac{(x_i - \mu)^2}{n}$$

onde μ é a média populacional.

Variância amostral

Medidas de dispersão

Variância amostral

A variância é dada pela soma do quadrado dos desvios de cada observação para a média amostral dividido por $n - 1$.

$$\mathbb{V}ar [X] = \sum_{i=1}^n \frac{(x_i - \bar{X})^2}{n - 1}$$

Desvio Padrão

Medidas de dispersão

- ▶ Como a variância é uma medida que expressa um desvio quadrático médio, sua interpretação não é trivial.
- ▶ Em algumas circunstâncias costuma-se utilizar o desvio padrão, definido como a raiz quadrada da variância.

$$dp(X) = \sqrt{\mathbb{V}ar[X]} = \sqrt{\sum_{i=1}^n \frac{(x_i - \bar{x})^2}{n-1}}$$

Desvio absoluto médio

Medidas de dispersão

Desvio absoluto médio

O desvio absoluto médio de um conjunto de dados é a média das distâncias entre cada dado e a média.

$$DAM = \sum_{i=1}^n \frac{|x_i - \bar{x}|}{n}$$

Medidas de dispersão

Example

x_i	Desvio $(x_i - \bar{x})$	Desvio Abs. $ x_i - \bar{x} $	Desvio ao quad. $(x_i - \bar{x})^2$
3	-2	2	4
4	-1	1	1
5	0	0	0
6	1	1	1
7	2	2	4
Total	0	6	10

- ▶ $\text{Var}[X] = \frac{10}{4} = 2.5 \rightarrow dp = \sqrt{2.5} \approx 1.58$
- ▶ $DAM[X] = 6/5 = 1.2$

Medidas de dispersão

R Exemplo

```
numeros <- c(3,4,5,6,7)

Variância <- var(numeros)
Variância
#[1] 2.5
desv.pad <- sd(numeros)
desv.pad
#[1] 1.581139
DAM <- mean(abs(numeros - mean(numeros)))
DAM
#[1] 1.2
```

Boxplot


Medidas de dispersão

O boxplot de Tukey é uma forma de visualizar os dados amostrados. O diagrama pode ser separado por três partes:

- ▶ Caixa (*Box*): A base da caixa é o valor $Q1$, o topo recebe o valor $Q3$. O $Q2$ é representado por uma linha que corta a caixa.
- ▶ Fios de Bigodes (*Whiskers*): Normalmente representa o menor valor abaixo de $Q1$ e o maior valor acima de $Q3$ dentro de uma região delimitada por uma vez e meia o intervalo interquartil ($Q3-Q1$)
- ▶ Pontos espúrios (*Outliers*): Pontos espúrios são pontos viesados, que podem ser considerados ruídos obtidos durante o processo de amostragem. Normalmente são considerados espúrios pontos situados acima de $Q3 + 1.5 \times (Q3 - Q1)$ e abaixo de $Q1 - 1.5 \times (Q3 - Q1)$

Boxplot

Medidas de posição



Quantil

Medidas de dispersão

R Exemplo

```
numeros <- rnorm(500)
# Exemplo 1
boxplot(numeros)

# Exemplo 2
library(ggplot2)
ggplot(as.data.frame(numeros)) +
  geom_boxplot(aes(x=numeros))
```

Transformações de dados

Transformações

Em estatística, a transformação de dados é a aplicação de uma função matemática determinística a cada ponto em um conjunto de dados. Ou seja, cada ponto de dados x_i é substituído pelo valor transformado $y_i = f(x_i)$, onde f é uma função.

As transformações são geralmente aplicadas de modo que os dados pareçam atender mais de perto às suposições de um procedimento de inferência estatística a ser aplicado ou para melhorar a interpretabilidade ou aparência dos gráficos.

Log

A transformação de log é, sem dúvida, a mais popular entre os diferentes tipos de transformações usadas para transformar dados distorcidos em aproximadamente conformidade com a normalidade. Se os dados originais seguem uma distribuição log-normal ou aproximadamente, os dados transformados em log seguem uma distribuição normal ou quase normal.

$$f(x) = \log(x)$$

```
Aula1_Dados$ln_Salario = log(Aula1_Dados$Salario)
```

normalização

Transformações

normalização

Em estatística, normalização é o processo de colocar diferentes variáveis na mesma escala. Normalmente, para padronizar variáveis, você calcula a média e o desvio padrão para uma variável. Então, para cada valor observado da variável, você subtrai a média e divide pelo desvio padrão.

$$f(x) = \frac{x - \bar{x}}{dp(x)}$$

```
Aula1_Dados$norm_Salario = scale(Aula1_Dados$Salario)
```

max-min

Transformações

max-min

A normalização mín-máx é uma das maneiras mais comuns de normalizar dados. Para cada item, o valor mínimo desse recurso é transformado em 0, o valor máximo é transformado em 1 e todos os outros valores são transformados em um decimal entre 0 e 1.

$$f(x) = \frac{x - \min(x)}{\max(x) - \min(x)}$$

```
MaxMin <- function(x){  
  ret <- (x - min(x))/(max(x) - min(x))  
  return(ret)  
}  
  
Aula1_Dados$maxMin_Salario <- MaxMin(Aula1_Dados$Salario)
```

box-cox

Uma transformação Box Cox é uma transformação de variáveis não normais em uma forma normal.

$$f(x; \lambda) = \begin{cases} \frac{x^\lambda - 1}{\lambda} & \text{se } \lambda \neq 0 \\ \log(x) & \text{se } \lambda = 0 \end{cases}$$

```
library(EnvStats)  
Aula1_Dados$boxcox_Salario <- boxcox(Aula1_Dados$Salario)
```

One-to-Hot

Transformações

One-Hot

Um one-hot é um grupo de funções que retornam o valor 1 (um) ou 0 (zero) para os diversos valores de uma variável.

Id	Food Name	Calories
1	Apple	95
2	Chicken	231
3	Broccoli	50

Id	Calories	Apple	Chicken	Broccoli
1	95	1	0	0
2	231	0	1	0
3	50	0	0	1

```
library(dplyr)
mpg %>% mutate(A4 = as.integer(model == "a4"))
```

Pivoting

Transformações

- ▶ Um problema comum é um conjunto de dados é muitas vezes queremos mudar a estrutura dos dados.

Aluno	P1	P2	LT
1	9.5	8.5	5.8
2	2.3	6.5	6.5
3	5.0	7.5	4.6

Note que podemos ter a mesma informação, em um formato diferente.

Id	Avaliação	Nota
1	P1	9.5
2	P1	2.3
3	P1	5.0
1	P2	8.5
2	P2	6.5
⋮	⋮	⋮

Pivoting

Transformações

A transformação “Pivot” de dados permite reorganizar as colunas e linhas em um relatório para que você possa visualizar os dados sob diferentes perspectivas.

```
library(dplyr)
library(tidyr)
tbl <- mpg %>% mutate(Carro_Id = row_number()) %>% select(Carro_Id, hwy, cty)
tbl
tbl %>% pivot_longer(cols = c("hwy", "cty"), names_to = "Variavel", values_to = "Valor")
```

Machine learning (ML) é utilizado para resolver uma variedade de problemas que podem ser categorizados em diferentes tipos. Cada tipo de problema requer abordagens e algoritmos específicos.

- ▶ **Problemas de Regressão:** Envolvem a previsão de uma variável contínua. O objetivo é estimar a relação entre as variáveis de entrada (*features*) e uma variável de saída contínua.
- ▶ **Problemas de Classificação:** Envolvem a previsão de uma variável categórica.
- ▶ **Problemas de Clustering:** Envolvem a agrupamento de dados sem classificação prévia. O objetivo é agrupar dados em clusters (grupos) de acordo com a similaridade entre eles.

- ▶ **Detecção de Anomalias:** Envolve a identificação de dados que não se encaixam no padrão geral. O objetivo é detectar eventos raros ou anômalos.
- ▶ **Sistemas de Recomendação** Envolvem a previsão de preferências do usuário e a recomendação de itens. O objetivo é sugerir produtos, serviços ou conteúdos que o usuário provavelmente gostará.

Table of Contents

Regressão linear simples

Hipoteses do modelo

Estimação de parâmetros

Propriedades dos estimadores

Variância dos estimadores

Estimando no R


O modelo de regressão simples

Imagine que tenhamos os seguintes dados.

Id	X	Y
1	x_1	y_1
2	x_2	y_2
3	x_3	y_3
4	x_4	y_4


O modelo de regressão simples

Vamos plotar os dados para ficar mais fácil de visualizar



O modelo de regressão simples

O que gostaríamos de fazer é aproximar os dados por um modelo linear.



O modelo de regressão simples

Atenção É importante ressaltar que neste momento estamos assumindo uma hipótese. A de que os dados podem ser representados por um modelo linear.

Hipótese 1

Linearidade nos Parâmetros: No modelo populacional, a variável dependente, y , está relacionada à variável independente, x , e o erro, u , conforme

$$y_i = \beta_0 + \beta_1 x_i + u_i \quad (1)$$

onde β_0 e β_1 são os parâmetros de intercepto populacional e inclinação, respectivamente.

O modelo de regressão simples


Terminologia

No modelo de regressão linear simples, onde $y = \beta_0 + \beta_1 x + u$, normalmente temos:

- ▶ y : variável dependente, ou variável Explicada
- ▶ x : variável independente, ou variável Explicativa, ou covariável, ou variável de controle;

O modelo de regressão simples

Note que mesmo assumindo um modelo linear, estamos cometendo erros na estimação.



O modelo de regressão simples

O erro pode ser “acima da reta”, ou seja estamos subestimando o valor de y . Ou o erro pode ser “abaixo da reta”, ou seja estamos superestimando o valor de y .

O modelo de regressão simples

Partindo do nosso modelo linear

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

Nosso desafio é portanto estimar os parâmetros β_0 e β_1

O modelo de regressão simples

Para garantir que a estimação é feita de maneira correta nossa amostra não pode conter nenhum viés de escolha, ou seja a amostra deve ser aleatória.

Hipótese 2

Amostragem Aleatória: Temos uma amostra aleatória de tamanho n , $\{(x_i, y_i) : i = 1, 2, \dots, n\}$, seguindo o modelo populacional.

O modelo de regressão simples

Além disso, devemos ter uma certa variação na variável x , o que implica a existência de erros de estimação.

Hipótese 3

Variação da amostra na variável explicativa: Os resultados da amostra em x , ou seja, $\{x_i, i = 1, \dots, n\}$, não são todos do mesmo valor.

O modelo de regressão simples

Para estimarmos os parâmetros vamos assumir que, uma vez que temos os valores de x , os erros que cometemos na aproximação tem média zero.

Hipótese 4

Média condicional zero: O erro u tem um valor esperado de zero dado qualquer valor da variável explicativa. O que implica também que o erro tem média incondicional zero.

$$\mathbb{E} [u_i|x] = 0 \Rightarrow \mathbb{E} [u_i] = 0 \quad (2)$$

O modelo de regressão simples

Vamos também assumir por enquanto que os erros tem a mesma variação. Isso será importante para fazermos inferência sobre as nossas estimações.

Hipótese 5

Homocedasticidade: O erro u tem a mesma variância dado qualquer valor da variável explicativa. Em outras palavras,

$$\text{Var} [u_i|x] = \sigma^2 \quad (3)$$

O modelo de regressão simples

Suposições de Gauss-Markov

Por conveniência, resumimos estas suposições, conhecidas como suposições de **Gauss-Markov**.

1. Suposição 1: Linear em Parâmetros
2. Suposição 2: Amostragem aleatória
3. Suposição 3: Variação da amostra na variável explicativa
4. Suposição 4: Média condicional zero
5. Suposição 5: Homoscedasticidade

O modelo de regressão simples

Estimação de parâmetros

Uma vez que temos a hipótese de $\mathbb{E}[u|x] = 0$, podemos reduzir nosso problema por meio da seguinte transformação:

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

$$\mathbb{E}[y_i] = \beta_0 + \beta_1 \mathbb{E}[x_i] + \mathbb{E}[u_i]$$

$$\mathbb{E}[y_i] = \beta_0 + \beta_1 \mathbb{E}[x_i] + 0$$

o que implica que

$$(y_i - \mathbb{E}[y_i]) = \beta_1(x_i - \mathbb{E}[x_i]) + u_i$$

O modelo de regressão simples

Estimação de parâmetros

Para ficarmos com uma notação mais suave, vamos fazer a seguinte mudança de notação:

$$\tilde{y}_i = y_i - \mathbb{E}[y_i]$$

$$\tilde{x}_i = x_i - \mathbb{E}[x_i]$$

logo temos o seguinte modelo

$$\tilde{y}_i = \beta_1 \tilde{x}_i + u_i$$

O modelo de regressão simples

Estimação de parâmetros

O que gostaríamos é poder escolher o parâmetro β_1 de tal maneira que o erro fosse o menor possível. Aqui temos de chamar a atenção a alguns pontos:

- ▶ Estamos interessados em reduzir o erro total, da amostra toda. Ou seja reduzir a média dos erros.
- ▶ Errar para cima ou para baixo é considerado erro. Ou seja os erros “negativos” não podem compensar erros “positivos”.

Para isso vamos escrever os erros como:

$$u_i = \tilde{y}_i - \beta_1 \tilde{x}_i$$

O modelo de regressão simples

Estimação de parâmetros

Para eliminar os erros negativos vamos transformar eles em positivos elevando cada um ao quadrado.

$$u_i^2 = (\tilde{y}_i - \beta_1 \tilde{x}_i)^2$$

O modelo de regressão simples

Estimação de parâmetros

Como estamos interessados em reduzir a soma de todos os erros vamos somar tudo. Para facilitar a notação iremos chamar essa soma de S

$$S = \sum_{i=1}^n u_i^2$$

$$S = \sum_{i=1}^n (\tilde{y}_i - \beta_1 \tilde{x}_i)^2$$

O modelo de regressão simples

Estimação de parâmetros

Para escolhermos o β_1 que minimiza a somatória S utilizamos cálculo, derivando e igualando a zero.

$$\frac{dS}{d\beta_1} = 0$$

Ao final teremos

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n \tilde{y}_i \tilde{x}_i}{\sum_{i=1}^n \tilde{x}_i^2} = \frac{\sum_{i=1}^n (y_i - \mathbb{E}[y_i])(x_i - \mathbb{E}[x_i])}{\sum_{i=1}^n (x_i - \mathbb{E}[x_i])^2}$$

O modelo de regressão simples

Estimação de parâmetros

Logo temos as seguintes equações:

$$\begin{aligned}\hat{\beta}_0 &= \bar{y} - \beta_1 \bar{x} \\ \hat{\beta}_1 &= \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}\end{aligned}$$

aonde $\bar{x} = \mathbb{E}[x_i]$ e $\bar{y} = \mathbb{E}[y_i]$

O modelo de regressão simples

Estimação de parâmetros

Atenção Note que as equações dos **estimadores** de β_0 e β_1 e estão escritos com um “^” ($\hat{\beta}_0$ e $\hat{\beta}_1$).

Isto é para indicar que estamos falando de estimadores dos parâmetros e não dos parâmetros propriamente ditos.

Propriedades algébricas das estatísticas OLS

Definimos a soma dos quadrados totais (SQT), a soma dos quadrados explicada (SQE) e a soma dos quadrados residuais (SQR), da seguinte forma:

$$\text{SQT} \equiv \sum_{i=1}^n (y_i - \bar{y})^2 \quad (4)$$

$$\text{SQE} \equiv \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = \sum_{i=1}^n \beta_1^2 (x_i - \bar{x})^2 \quad (5)$$

$$\text{SQR} \equiv \sum_{i=1}^n \hat{u}_i^2 \quad (6)$$

Existem várias propriedades algébricas úteis das estimativas OLS e suas estatísticas associadas. Vamos agora cobrir os três mais importantes deles.

Propriedades algébricas das estatísticas OLS

- ▶ SQT é uma medida da variação total da amostra no y_i ; ou seja, mede a dispersão dos y_i na amostra.
- ▶ SQE mede a variação amostral em $\hat{y}$ (onde usamos o fato de que $\mathbb{E}[\hat{y}] = \bar{y}$),
- ▶ SQR mede a variação da amostra nos resíduos ou seja $\hat{u}_i$.

A variação total em y sempre pode ser expressa como a soma da variação explicada (SQE) e da variação não explicada (SQR).

$$\text{SQT} = \text{SQE} + \text{SQR} \quad (7)$$

Qualidade de ajuste

- ▶ Muitas vezes, é útil calcular um número que resuma o quão bem a linha de regressão OLS se ajusta aos dados.
- ▶ Assumindo que a soma dos quadrados totais, SQT , não é igual a zero podemos dividir (2,36) por SQT para obter $1 = SSE/SQT + SSR/SQT$.
- ▶ O R-quadrado da regressão, às vezes chamado de coeficiente de determinação, é definido como

$$R^2 \equiv \frac{SSE}{SQT} = 1 - \frac{SSR}{SQT} \quad (8)$$

Estimando a variância do erro

- ▶ As fórmulas das variâncias dos estimadores permitem isolar os fatores que contribuem para $\text{Var}(\hat{\beta}_1)$ e $\text{Var}(\hat{\beta}_0)$. Mas essas fórmulas são desconhecidas, exceto no caso extremamente raro em que σ^2 é conhecido.
- ▶ No entanto, podemos usar os dados para estimar σ^2 , o que nos permite estimar $\text{Var}(\hat{\beta}_1)$ e $\text{Var}(\hat{\beta}_0)$.

Atenção Neste ponto é importante fazer uma distinção entre resíduos e erros.

- ▶ Erros: são decorrentes da aproximação do modelo teórico.
- ▶ Resíduos: são as estimativas dos erros calculados a partir dos parâmetros estimados.

$$\text{erros} \equiv u_i$$

$$\text{Resíduos} \equiv \hat{u}_i$$

- ▶ Assumimos que as estimativas de intercepto e inclinação, $\hat{\beta}_0$ e $\hat{\beta}_1$, foram obtidos para a amostra de dados dada.
- ▶ Dados $\hat{\beta}_0$ e $\hat{\beta}_1$, podemos obter o valor ajustado $\hat{y}_i$ para cada observação.

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i \quad (9)$$

- ▶ O resíduo OLS associado à observação i , $\hat{u}_i$, é a diferença entre y_i e seu valor ajustado, $\hat{y}_i$.

$$\hat{u}_i = y_i - \hat{y}_i \quad (10)$$

Estimando a variância do erro

O estimador imparcial de σ^2 que usaremos faz um ajuste de graus de liberdade

$$\hat{\sigma}^2 = \frac{1}{(n-2)} \sum_{i=1}^n \hat{u}_i^2 \quad (11)$$

Variações dos Estimadores OLS

$$\text{Var} \left(\hat{\beta}_1 \right) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (12)$$

$$\text{Var} \left(\hat{\beta}_0 \right) = \frac{\sigma^2 \sum_{i=1}^n x_i^2 / n}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (13)$$

Estimando no R

R Exemplo

```
mdl <- lm(mpg ~ hp + cyl + disp + hp, data = mtcars)
summary(mdl)
# Call:
# lm(formula = mpg ~ hp + cyl + disp + hp, data = mtcars)
#
# Residuals:
#   Min       1Q   Median       3Q      Max
# -4.0889 -2.0845 -0.7745  1.3972  6.9183
#
# Coefficients:
#   Estimate Std. Error t value Pr(>|t|)
# (Intercept)  34.18492     2.59078   13.195 1.54e-13 ***
#   hp          -0.01468     0.01465   -1.002  0.3250
#   cyl         -1.22742     0.79728   -1.540  0.1349
#   disp        -0.01884     0.01040   -1.811  0.0809 .
# ---
# Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#
# Residual standard error: 3.055 on 28 degrees of freedom
# Multiple R-squared:  0.7679,    Adjusted R-squared:  0.743
# F-statistic: 30.88 on 3 and 28 DF,  p-value: 5.054e-09
```

Table of Contents

Shrinkage Methods

Ridge Regression

Lasso

Seleção variável

Lasso vs Regressão Rígida

Estimando no R

Introdução

- ▶ Os métodos apresentados anteriormente envolvem o uso de mínimos quadrados para ajustar um modelo linear que inclui um subconjunto de preditores.
- ▶ Alternativamente, podemos usar uma técnica que modela todos os preditores p restringindo ou regularizando as estimativas dos coeficientes. Este processo efetivamente reduz as estimativas dos coeficientes para zero.
- ▶ A redução das estimativas dos coeficientes pode reduzir significativamente a sua variância, conduzindo a um modelo mais estável e generalizável.
- ▶ As duas técnicas mais conhecidas para reduzir os coeficientes de regressão a zero são a Regressão Rígida (*Ridge Regression*) e o Lasso.

Ridge Regression

A Regressão Rígida, também conhecida como regularização L2, é uma técnica usada para resolver algumas das limitações da regressão linear de mínimos quadrados ordinários (OLS), especialmente quando o modelo tem um grande número de características ou quando há multicolinearidade (alta correlação entre independentes variáveis).

Ridge Regression

- ▶ A Regressão Rígida é muito semelhante aos mínimos quadrados, exceto que os coeficientes de regressão de crista são estimados minimizando uma quantidade ligeiramente diferente.
- ▶ Em particular, as estimativas da Regressão Rígida são os valores que minimizam os erros quadraticos, sujeitos a uma restrição

Ridge Regression

$$\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2 = \text{RSS} + \lambda \sum_{j=1}^p \beta_j^2 \quad (14)$$

- ▶ onde $\lambda \geq 0$ é um parâmetro de ajuste, a ser determinado separadamente.

Parâmetro de Regularização

- ▶ Quando $\lambda = 0$, a Regressão Rígida torna-se equivalente à regressão OLS.
- ▶ A medida que λ aumenta, a magnitude dos coeficientes é reduzida, o que ajuda a mitigar o impacto da multicolinearidade e evita o *overfitting*.
- ▶ A escolha de λ é crucial e normalmente determinado por meio de técnicas como validação cruzada.

Parâmetro de Regularização

- ▶ Como temos um parâmetro de Regularização para todos os coeficientes, temos que a escala das variáveis dependentes influenciam diretamente a penalizacao.
- ▶ Portanto, é recomendável aplicar a Regressão Rígida após a padronização dos preditores.

Regressão de Rígida vs MQO

- ▶ A Regressão Rígida melhora em relação aos mínimos quadrados, equilibrando a compensação entre viés e variância. À medida que o parâmetro de regularização (λ) aumenta, a flexibilidade do ajuste da regressão da crista diminui, levando à redução da variância, mas ao aumento do viés.
- ▶ **Variância e Viés:** Quando $\lambda = 0$ a variância é alta, mas não há viés. À medida que λ aumenta, a variância das previsões diminui substancialmente, com apenas um ligeiro aumento no viés inicialmente.

- ▶ A Regressão Rígida tem uma desvantagem notável em comparação com métodos de seleção de variáveis. Outros métodos normalmente selecionam modelos que envolvem apenas um subconjunto de variáveis, enquanto a Regressão Rígida inclui todos os p preditores no modelo final.
- ▶ O Lasso (do inglês : “**Least Absolute Shrinkage and Selection Operator**”) é uma alternativa moderna à Regressão rígida que aborda sua principal desvantagem.

The Lasso

Os coeficientes do laço ($\hat{\beta}_L^\lambda$) minimizam a seguinte quantidade:



$$\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p |\beta_j| = \text{RSS} + \lambda \sum_{j=1}^p |\beta_j| \quad (15)$$

The Lasso

- ▶ Comparando isso com a Regressão Rígida, vemos que o laço substitui o termo β_j^2 na Regressão Rígida por $|\beta_j|$.
- ▶ Em termos estatísticos, o laço usa uma penalidade ℓ_1 (L1) em vez da penalidade ℓ_2 (L2) usada na Regressão Rígida. A norma ℓ_1 de um vetor de coeficientes β é dada por $\|\beta\|_1 = \sum |\beta_j|$.

- ▶ **O Lasso reduz as estimativas dos coeficientes para zero.** No entanto, a penalidade ℓ_1 tem o efeito adicional de forçar alguns coeficientes a serem exatamente zero quando λ é suficientemente grande.
- ▶ Isso resulta em um modelo esparsa, realizando efetivamente a seleção de variáveis, incluindo apenas os preditores mais importantes.

The Lasso



Seleção variável

- ▶ O laço, diferentemente da Regressão Rígida, resulta em algumas estimativas de coeficiente sendo exatamente zero. Essa diferença pode ser compreendida através de suas respectivas formulações e restrições.
- ▶ Na Regressão Rígida, a região de restrição é um círculo, enquanto no Lasso, a região de restrição é um losango.

Seleção variável do Lasso

- ▶ **Valores s grandes:** quando a região de restrição é grande o suficiente para conter $\hat{\beta}$, tanto a Regressão Rígida quanto as estimativas de Lasso serão idênticas ao mínimo estimativas de quadrados. Este cenário corresponde a $\lambda = 0$ em suas respectivas funções de penalidade.
- ▶ **Valores de s menores:** Quando a região de restrição não contém $\hat{\beta}$, as estimativas serão diferentes. As estimativas de mínimos quadrados ficarão fora do losango e do círculo, levando a diferentes efeitos de contração.

Lasso vs Regressão Rígida

- ▶ O Lasso produz modelos mais simples e interpretáveis que envolvem apenas um subconjunto dos preditores.
- ▶ **Variância e viés:** O Lasso e a Regressão Rígida demonstram comportamento semelhante em termos de variância e viés.
- ▶ **Comparação de modelos:** A Regressão Rígida tende a ter uma variância ligeiramente menor, levando a um erro quadrático médio (MSE) marginalmente menor em comparação com o Lasso.

Exemplo

Estimando no R

Usando o conjunto de dados ‘mtcars’, podemos demonstrar como a regressão Rígida lida efetivamente com preditores correlacionados para prever milhas por galão (mpg).

Example

Utilizando a base mtcars, estime uma Regressão Rígida para encontrar os coeficientes dos estimadores seguindo a equação abaixo.

$$mpg_i = \beta_0 - \sum_{j=1}^p \beta_j x_{ij} + e_i \quad (16)$$

Onde p representa o universo de variáveis dependentes.

Exemplo

Base de dados

A base de dados 'mtcars' contém 32 observações em 11 variáveis.

- ▶ **mpg:** milhas/galão (EUA)
- ▶ **cil:** Número de cilindros
- ▶ **displ:** Deslocamento (pol. cu.)
- ▶ **hp:** Potência bruta
- ▶ **drat:** Relação do eixo traseiro
- ▶ **peso:** peso do veículo por 1000 libras
- ▶ **qsec:** tempo para percorrer 1/4 milha (sec)
- ▶ **vs:** Motor (0 = em 'V', 1 = em linha)
- ▶ **Transmissão:** (0 = automática, 1 = manual)
- ▶ **marcha:** Número de marchas à frente
- ▶ **carb:** Número de carburadores

Exemplo

Base de dados

```
> head(mtcars)
```

	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
Mazda RX4	21.0	6	160	110	3.90	2.620	16.46	0	1	4	4
Mazda RX4 Wag	21.0	6	160	110	3.90	2.875	17.02	0	1	4	4
Datsun 710	22.8	4	108	93	3.85	2.320	18.61	1	1	4	1
Hornet 4 Drive	21.4	6	258	110	3.08	3.215	19.44	1	0	3	1
Hornet Sportabout	18.7	8	360	175	3.15	3.440	17.02	0	0	3	2
Valiant	18.1	6	225	105	2.76	3.460	20.22	1	0	3	1

Exemplo

Base de dados

Carregue o pacote glmnet para Regressão Rígida/Lasso.

```
rm(list = ls())

library(dplyr)
library(glmnet)

# Deixa a base mtcars como um data frame
tbl <- as.data.frame(mtcars)
```

Exemplo



Padronizacao

- ▶ Defina X como a matriz de preditores (todas as colunas exceto mpg).
- ▶ Defina y como a variável de resposta (mpg).
- ▶ Padronize os preditores usando `scale()` para garantir que todas as variáveis estejam na mesma escala.

```
boxplot(tbl[, -1])  
  
y <- tbl %>% select(mpg) %>% scale(center = TRUE, scale = FALSE) %>% as.matrix()  
X <- tbl %>% select(-mpg) %>% scale() %>% as.matrix()  
boxplot(X)
```

Exemplo

Padronizacao



Exemplo

Validação cruzada

- ▶ Use `cv.glmnet()` com $\alpha = 0$ para ajustar o *lambda* da Regressão Rígida.
- ▶ Regressão Rígida: $\alpha = 0$
- ▶ Lasso: $\alpha = 1$

```
# Ridge Regression - cross-validation -----
lambdas_to_try <- 10^seq(-3, 4, length.out = 100)


ridge_cv <- cv.glmnet(X, y,
                     alpha = 0,
                     lambda = lambdas_to_try,
                     standardize = FALSE,
                     nfolds = 10)

# Plot cross-validation results
plot(ridge_cv)

# Best cross-validated lambda
lambda_cv <- ridge_cv$lambda.min
```

Exemplo

Validação cruzada



Exemplo

Estimaco

- ▶ Estime os coeficientes do modelo utilizando o λ escolhido.
- ▶ Calcule o erro quadrático médio (MSE).
- ▶ Visualize como os coeficientes se comportam para diferentes valores lambda.

```
# Ridge Regression - coeficientes, SSR e R2 -----
model <- glmnet(X, y, alpha = 0, lambda = lambda_cv, standardize = FALSE)

# Coeficientes do modelo
coef(model)

# Fitted values
y_hat <- predict(model, X)
SSR <- t(y - y_hat) %*% (y - y_hat)
rsq_ridge <- cor(y, y_hat)^2

cat(sprintf("SSR: %5.3f\n R2: %5.3f", SSR, rsq_ridge))

# Ridge Regression - coeficientes vs lambda -----

res <- glmnet(X, y, alpha = 0, lambda = lambdas_to_try, standardize = FALSE)
plot(res, xvar = "lambda")
```

Exemplo

Estimação




Table of Contents

Regressão Logística

Modelos de resposta binária

Modelo Logit

Donner Party

Modelos de resposta binária

Considere uma equação geral do tipo:

$$y_i^* = \beta_0 + \beta_1 x_{1,i} + \epsilon_i \equiv X_i \beta + \epsilon_i \quad (17)$$

O problema é que não observamos y_i . Em vez disso, observamos a variável binária:

$$y_i = \begin{cases} 1 & \text{if } y_i^* = \beta' x_i + \epsilon_i > c \\ 0 & \text{caso contrario} \end{cases} \quad (18)$$

Aqui, a probabilidade de $y_i = 1$ é igual à probabilidade de y_i^* ser maior que uma constante c , onde c é um limite. O limite é facilmente convertido em 0 ajustando o termo constante no modelo. Assim, para simplificar, reescrevemos a condição como

$$y_i = \begin{cases} 1 & \text{if } y_i^* = \beta' x_i + \epsilon_i > 0 \\ 0 & \text{caso contrario} \end{cases} \quad (19)$$

Modelos de resposta binária

Observe que a probabilidade de y_i observado ser um pode ser escrito usando y_i^*

$$\begin{aligned}\mathbb{P}(y_i = 1) &= \mathbb{P}(y_i^* > 0) \\ &= \mathbb{P}(\epsilon_i > -\beta' x_i)\end{aligned}\tag{20}$$

Assumimos que o termo de erro ϵ_i tem uma função de distribuição cumulativa de $F(\epsilon_i)$ e onde $f(\epsilon_i)$ é a função de densidade de probabilidade de $F(\epsilon_i)$. Então nós temos

$$\mathbb{P}(\epsilon_i > -\beta' X_i) = 1 - F(-\beta' X_i)\tag{21}$$

Se a distribuição for simétrica temos:

$$\mathbb{P}(\epsilon_i > -\beta' X_i) = F(\beta' X_i)\tag{22}$$

Modelos de resposta binária

Logit

Sendo assim basta escolhermos uma distribuição simétrica para modelarmos a “probabilidade” de ocorrência da variável y_i .

Para isso vamos utilizar a distribuição Logística (contudo seria possível utilizar outra distribuição simétrica). Para a distribuição logística temos:

$$F(\beta'x) = \frac{e^{\beta'x}}{1 + e^{\beta'x}} \quad (23)$$

Ou seja, para um modelo de uma variável independente, temos o seguinte modelo econométrico:

$$p_i = \frac{e^{(\beta_0 + \beta_1 x_{1,i})}}{1 + e^{(\beta_0 + \beta_1 x_{1,i})}} \quad (24)$$

Exemplo - Donner Party

Em 1846, as famílias Donner e Reed deixaram Springfield, Illinois, para a Califórnia por caravana. Em julho, a *Donner Party*, como ficou conhecida, alcançou Fort Bridger, Wyoming. Lá, seus líderes decidiram tentar uma nova e rota para o Vale do Sacramento. Tendo atingido seu tamanho total de 87 pessoas e 20 vagões, o grupo se atrasou devido a uma difícil travessia do Cordilheira Wasatch e novamente na travessia do deserto a oeste do *Great Salt Lake*. O grupo ficou preso no leste das montanhas de Nevada quando a região foi atingida por fortes nevascas no final de outubro. Quando o último sobrevivente foi resgatado em 21 de abril de 1847, 40 dos 87 membros morreram de fome e exposição ao frio extremo.

Fonte: Ramsey, F.L. and Schafer, D.W. (2002). *The Statistical Sleuth: A Course in Methods of Data Analysis* (2nd ed)

Donner Party - Perguntas

Objetivo da análise

Objetivo

- ▶ Qual é a relação entre sobrevivência e gênero?
- ▶ Qual é a probabilidade de sobrevivência em função da idade?
- ▶ Depois de levar em consideração a idade, as mulheres têm mais probabilidade de sobreviver a condições adversas do que os homens?
- ▶ A idade afeta a taxa de sobrevivência de homens e mulheres de forma diferente?

Donner Party - Dados

Dados

```
tbl <- read.csv("./database/DonnerParty.csv")  
head(tbl)
```

	Age	Sex	Status
1	23.00	Male	Died
2	40.00	Female	Survived
3	40.00	Male	Survived
4	30.00	Male	Died
5	28.00	Male	Died
⋮			
43	23.00	Male	Survived
44	24.00	Male	Died
45	25.00	Female	Survived

Donner Party - Dados

Diagramas de dispersão

Vamos analisar as distribuições marginais e os diagramas de dispersão.


```
table(tbl[, c(3,2)])
```

	Female	Male
Died	5	20
Survived	10	10

Donner Party

Diagramas de dispersão

```
library(ggplot2)
ggplot(tbl) +
  geom_boxplot(aes(x = Survived, y = Age))
```



Donner Party

Modelando a probabilidade de sobrevivência em função da idade

Modelando a probabilidade de sobrevivência em função da idade

$$\mathbb{P}(y = 1|x_1) = \beta_0 + \beta_1 x_1 \quad (25)$$

- ▶ **Modelo de regressão linear:** Sobrevivência esperada do modelo dada a idade:

$$\mathbb{E}[y = 1|x_1] = \beta_0 + \beta_1 x_1 \quad (26)$$

Problemas:

- ▶ Não linearidade - um modelo linear pode fornecer valores previstos fora do intervalo $(0, 1)$
- ▶ Heteroscedasticidade - a variância $np(1 - p)$ não é constante. Isso se deve ao fato de que y segue uma distribuição de **Bernoulli**.

Exemplo - Donner Party

Modelando a probabilidade de sobrevivência em função da idade

```
Call:
lm(formula = Survived ~ Age, data = DonnerParty)

Residuals:
    Min       1Q   Median       3Q      Max
-0.66886 -0.49521 -0.06775  0.45136  0.74524

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.869232   0.197106   4.410  6.8e-05 ***
Age         -0.013358   0.005777  -2.312   0.0256 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
[...]
```

O modelo estimado é:

$$\mathbb{E}[y = 1|x_1] = 0.8692 - 0.01336 \times x_1 \quad (27)$$

Considere prever a sobrevivência para uma pessoa de 70 anos:

$$\mathbb{E}[Survived = 1|Age = 70] = 0.8692 - 0.01336 \times 70 = -0,0658 \quad (28)$$

Este modelo prevê uma probabilidade negativa de sobrevivência.

Exemplo - Donner Party

Modelando a probabilidade de sobrevivência em função da idade

- (Solução adequada): modelo de regressão logística

$$\begin{aligned}\pi_i &= \frac{\exp\{\beta_0 + \beta_1 X_{1,i}\}}{1 + \exp\{\beta_0 + \beta_1 X_{1,i}\}} \\ \log\left(\frac{\pi_i}{1 - \pi_i}\right) &= \beta_0 + \beta_1 X_{1,i}\end{aligned}\tag{29}$$

onde $\pi_i = \mathbb{P}(Survived = 1)$ probabilidade de sobrevivência para a pessoa i , e $X_{1,i}$ é a idade de uma pessoa i .

Exemplo - Donner Party

Modelando a probabilidade de sobrevivência em função da idade

```
Call:
glm(formula = Survived ~ Age, family = binomial("logit"), data = DonnerParty)

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-1.5401  -1.1594  -0.4651   1.0842   1.7283

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)  1.81852    0.99937   1.820  0.0688 .
Age          -0.06647    0.03222  -2.063  0.0391 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
[...]
```

O modelo estimado é

$$\log \left(\frac{\pi_i}{1 - \pi_i} \right) = 1.8183 - 0.0665X_{1i} \quad (30)$$

Exemplo - Donner Party

Modelando a probabilidade de sobrevivência em função da idade

- ▶ A probabilidade de sobrevivência esperada de um indivíduo de 70 anos:

$$\hat{\pi} = \Pr(\text{ survival }) = \frac{\exp \{1.8183 - 0.0665 \times 70\}}{1 + \exp \{1.8183 - 0.0665 \times 70\}} = 0.055 \quad (31)$$

- ▶ o coeficiente β_1 é negativo, indicando que as chances de sobrevivência diminuem com a idade.

Exemplo - Donner Party

Modelando a probabilidade de sobrevivência em função da idade

- ▶ Depois de levar em consideração a idade, as mulheres têm mais probabilidade de sobreviver a condições adversas do que os homens?
- ▶ Isso envolverá o ajuste no modelo, mas o modelo final fica:

$$\log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \epsilon_i \quad (32)$$

Exemplo - Donner Party

Modelando a probabilidade de sobrevivência em função da idade

```
Call:
glm(formula = survive ~ age + sex, family = binomial("logit"))

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-1.7445  -1.0441  -0.3029   0.8877   2.0472

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)   3.23041    1.38686   2.329  0.0198 *
age          -0.07820    0.03728  -2.097  0.0359 *
sex          -1.59729    0.75547  -2.114  0.0345 *
---
[...]
```

O modelo estimado é

$$\log \frac{\pi_i}{1 - \pi_i} = 3.23041 - 0.07820X_{1,i} - 1.59729X_{2,i} \quad (33)$$

Exemplo - Donner Party

Modelando a probabilidade de sobrevivência em função da idade

- ▶ As análises anterior assumem que o efeito do gênero na sobrevivência não depende da idade; ou seja, não há interação entre idade e sexo. Para testar a interação, vamos analisar o modelo:

$$\log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{1i} X_{2i} \quad (34)$$

Exemplo - Donner Party

Modelando a probabilidade de sobrevivência em função da idade

```
Call:
glm(formula = survive ~ age * sex, family = binomial("logit"))

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-2.2279  -0.9388  -0.5550   0.7794   1.6998

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept)  7.24638    3.20517   2.261  0.0238 *
age         -0.19407    0.08742  -2.220  0.0264 *
sex         -6.92805    3.39887  -2.038  0.0415 *
age:sex       0.16160    0.09426   1.714  0.0865 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
[...]
```

O modelo estimado é

$$\log\left(\frac{\pi_i}{1 - \pi_i}\right) = 7.24638 - 0.19407X_{1,i} - 6.92805X_{2,i} + 0.16160X_{3,i} \quad (35)$$

Table of Contents

Métricas de avaliação

Métricas de Regressão

Métricas nos resíduos

Métricas de performance

Métricas de previsão

Confusion matrix

Introdução às Métricas de Regressão

- ▶ Nesta sessão, abordaremos várias métricas usadas para avaliar o desempenho de modelos de regressão. Compreender essas métricas é crucial para selecionar o melhor modelo e melhorar seu desempenho preditivo.
- ▶ Diferentes tipos de métricas de regressão, suas fórmulas e como interpretá-las. Serão fornecidos exemplos práticos em R para melhor compreensão.

Erro Médio Absoluto (MAE)

- ▶ O Erro Médio Absoluto (MAE) mede a magnitude média dos erros em um conjunto de previsões, sem considerar sua direção.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (36)$$

```
actual <- c(1, 2, 3, 4, 5)
predicted <- c(1.2, 2.1, 2.8, 3.6, 5.3)
mae <- mean(abs(actual - predicted))
print(mae)
```

Erro Quadrático Médio (MSE)

- ▶ O Erro Quadrático Médio (MSE) mede a média das diferenças quadráticas entre os valores previstos e os valores reais. O MSE dá mais peso a erros maiores, tornando-o sensível a outliers.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (37)$$

```
mse <- mean((actual - predicted)^2)
print(mse)
```

Raiz do Erro Quadrático Médio (RMSE)

- ▶ A Raiz do Erro Quadrático Médio (RMSE) é a raiz quadrada do Erro Quadrático Médio.
- ▶ O RMSE fornece uma métrica de erro nas mesmas unidades da variável alvo, facilitando a interpretação.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (38)$$

```
rmse <- sqrt(mean((actual - predicted)^2))  
print(rmse)
```

Erro Percentual Absoluto Médio (MAPE)

- ▶ O Erro Percentual Absoluto Médio (MAPE) mede a média dos erros percentuais absolutos. Ele fornece uma taxa de erro percentual, facilitando a interpretação da precisão relativa das previsões.

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100 \quad (39)$$

```
mape <- mean(abs((actual - predicted) / actual)) * 100  
print(mape)
```

R-quadrado (R^2)

- O R-quadrado, também conhecido como coeficiente de determinação, representa a proporção da variância na variável dependente que é previsível a partir das variáveis independentes.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (40)$$

```
y_bar <- mean(actual)
ss_tot <- sum((actual - y_bar)^2)
ss_res <- sum((actual - predicted)^2)
r_squared <- 1 - (ss_res / ss_tot)
print(r_squared)
```

R-quadrado Ajustado

- ▶ O R-quadrado Ajustado ajusta o valor do R-quadrado com base no número de preditores no modelo. Ele leva em conta a complexidade do modelo e ajuda a comparar modelos com diferentes números de preditores.

$$R_{Ajust}^2 = 1 - \left(\frac{1 - R^2}{n - k - 1} \right) \quad (41)$$

```
n <- length(actual)
k <- length(predicted) - 1
adjusted_r_squared <- 1 - ((1 - r_squared) * (n - 1) / (n - k - 1))
print(adjusted_r_squared)
```

Matriz de Confusão

- ▶ A Matriz de Confusão é uma tabela que descreve o desempenho de um modelo de classificação, mostrando os valores de TP, TN, FP e FN.

	Previsto Positivo	Previsto Negativo
Real Positivo	TP	FN
Real Negativo	FP	TN

(42)

```
table(actual, predicted)
```

Acurácia

- A Acurácia mede a proporção de previsões corretas entre o total de casos avaliados.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (43)$$

```
actual <- c(1, 0, 1, 1, 0)
predicted <- c(1, 0, 1, 0, 0)
accuracy <- mean(actual == predicted)
print(accuracy)
```

- A Precisão mede a proporção de verdadeiros positivos entre os positivos previstos.

$$Precision = \frac{TP}{TP + FP} \quad (44)$$

```
TP <- sum(actual == 1 & predicted == 1)
FP <- sum(actual == 0 & predicted == 1)
precision <- TP / (TP + FP)
print(precision)
```

Revocação (Recall)

- ▶ A Revocação, também conhecida como Sensibilidade, mede a proporção de verdadeiros positivos entre os positivos reais.

$$Recall = \frac{TP}{TP + FN} \quad (45)$$

```
FN <- sum(actual == 1 & predicted == 0)
recall <- TP / (TP + FN)
print(recall)
```

Medida F1

- ▶ A Medida F1 é a média harmônica da Precisão e da Revocação, fornecendo uma única métrica que equilibra ambas.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (46)$$

```
f1_score <- 2 * (precision * recall) / (precision + recall)
print(f1_score)
```


AUC-ROC

Área Sob a Curva ROC

- ▶ A Curva ROC é um gráfico que mostra a taxa de verdadeiros positivos (TPR) contra a taxa de falsos positivos (FPR) em vários limiares de classificação.
- ▶ A AUC (Área Sob a Curva) mede a capacidade de um modelo em distinguir entre as classes.

```
library(pROC)
data(aSAH)
str(aSAH)
roc_curve <- roc(aSAH$outcome, aSAH$s100b, levels=c("Good", "Poor"))
plot(roc_curve)
auc(roc_curve)
```

AUC-ROC (Área Sob a Curva ROC)



Escolhendo a Métrica Correta

- ▶ Selecionar a métrica de classificação apropriada é crucial para a avaliação precisa do modelo.
- ▶ Considere fatores como a prevalência da classe, o custo de falsos positivos e falsos negativos, e o contexto específico da aplicação.
- ▶ Use múltiplas métricas para obter uma compreensão abrangente do desempenho do modelo.

Table of Contents

K-Nearest Neighbors

Métricas de distância


Vantagens e desvantagens do KNN

K-Nearest Neighbors


- ▶ Método de análise baseado nos vizinhos mais próximos;
- ▶ Está entre os mais simples de todos os algoritmos de aprendizado de máquina. Não tem nenhum treinamento ou modelo explícito.
- ▶ Pode ser usado tanto para classificação como regressão;

K-Nearest Neighbors


- ▶ O algoritmo de classifica usando a maioria dos votos de k pontos de treinamento mais próximos
- ▶ Note que a quantidade de pontos considerados depende da distancia que consideramos.



(a) 1-nearest neighbor



(b) 2-nearest neighbor



(c) 3-nearest neighbor

K-Nearest Neighbors

- O algoritmo K-NN não computa explicitamente a distancia limite para decisão.





Image by MIT OpenCourseWare.

Cada segmento de linha é equidistante aos pontos vizinhos.


Compreendendo o KNN

- ▶ KNN usa uma vizinhança local para obter uma classificação/predição. A suposição é que os itens nesta vizinhança são provavelmente semelhantes aos seus vizinhos.
- ▶ Ele procura por itens mais próximos do ponto a ser determinado.
- ▶ O tamanho da vizinhança local a ser pesquisado é determinado pelo parâmetro k , ou seja, pela quantidade de vizinhos a ser considerado.



Métricas de distância

- ▶ Dado o parâmetro k (quantidade de vizinhos a ser considerado), o KNN calcula a distância entre os pontos que requerem classificação e seus vizinhos.
- ▶ Como podemos medir a “distancia” de um vizinho?



Métricas de distância

- Considere duas observações i e j . A distância entre as observações i e j pode ser medida de muitas maneiras.

Distância euclidiana: A distância euclidiana é frequentemente usada para atributos contínuos.

$$\mathcal{D}(x_i, x_j) = \sqrt{\sum_{m=1}^n (x_{im} - x_{jm})^2} \quad (47)$$

Métricas de distância

Outras métricas utilizadas

Métrica Manhattan:

$$\mathcal{D}(x_i, x_j) = \sum_{m=1}^n |x_{im} - x_{jm}| \quad (48)$$

Métrica de Minkowski:

$$\mathcal{D}(x_i, x_j) = \left(\sum_{m=1}^n (|x_{im} - x_{jm}|)^q \right)^{\frac{1}{q}} \quad (49)$$

Métrica de Canberra:

$$\mathcal{D}(x_i, x_j) = \sum_{m=1}^n \frac{|x_{im} - x_{jm}|}{|x_{im}| + |x_{jm}|} \quad (50)$$

Métricas de distância

Observações


- ▶ Tanto a distância euclidiana quanto a distância de Manhattan podem ser consideradas casos especiais de distância de Minkowski.
- ▶ Como estamos lidando com distancias é importante que os dados estejam na mesma “escala”. Sendo assim é importante padronizar os dados.

Atenção

Se você alterar a função de distância, você alterará como os pontos de dados são classificados.

Um exemplo

As observações da amostra são mostradas na tabela abaixo. Um total de onze observações rotuladas estão disponíveis, e nossa tarefa é prever a classe da 12a observação, que tem uma idade padronizada de 0,807 e um peso padronizado de -0,963.



Um exemplo

Observação	Idade	Peso	Class.
1	-1.015	-0.797	blacklip
2	-0.223	-0.458	blacklip
3	0.569	-0.12	blacklip
4	-1.411	-1.135	blacklip
5	-0.223	0.523	blacklip
6	1.123	-1.169	blacklip
7	-1.174	0.117	blacklip
8	0.173	-0.425	greenlip
9	1.757	0.218	greenlip
10	0.807	2.215	greenlip
11	-0.382	1.031	greenlip
12	0.807	-0.963	?

Um exemplo

Para ilustrar o cálculo, usaremos a distância euclidiana. Então para exemplo, a distância entre a nova observação 12 e a observação 11 é calculada como:

$$\begin{aligned}\mathcal{D}(x_{12}, x_{11}) &= \sqrt{(x_{121} - x_{111})^2 + (x_{122} - x_{112})^2} \\ &= \sqrt{(0.807 - (-0.382))^2 + (-0.963 - 1.031)^2} \\ &= \sqrt{1.414 + 3.976} \\ &= \sqrt{5.390} \\ &= 2.322\end{aligned}\tag{51}$$

Um exemplo

Observação	Idade	Peso	Distancia	Rank	Class
1	-1.015	-0.797	1.830	7	blacklip
2	-0.223	-0.458	1.147	4	blacklip
3	0.569	-0.12	0.876	3	blacklip
4	-1.411	-1.135	2.225	8	blacklip
5	-0.223	0.523	1.808	6	blacklip
6	1.123	-1.169	0.377	1	blacklip
7	-1.174	0.117	2.256	9	blacklip
8	0.173	-0.425	0.832	2	greenlip
9	1.757	0.218	1.516	5	greenlip
10	0.807	2.215	3.178	11	greenlip
11	-0.382	1.031	2.322	10	greenlip
12	0.807	-0.963	-	-	blacklip

Making K-NN More Powerful

Um bom valor para k pode ser determinado considerando uma faixa de k valores.

- ▶ k muito pequeno: vamos modelar o ruído
- ▶ k muito grande: os vizinhos incluem muitos pontos de outras classes

Vantagens e desvantagens do KNN

Vantagens

- ▶ Simples e poderoso. Não há necessidade de ajustar parâmetros complexos para construir um modelo.
- ▶ Nenhum treinamento envolvido. Novos exemplos de treinamento podem ser adicionado facilmente.

Desvantagens

- ▶ Caro e lento: a medida que se aumenta a quantidade de atributos e quantidade de elementos o algoritmo fica mais lento.
- ▶ Para determinar o vizinho mais próximo de um novo ponto x , deve-se calcular a distância para todos os exemplos de treinamento m . Tempo de execução é lento.

Exemplo

Example

as Previsão do desempenho do aluno com k-vizinhos mais próximos (k-NN)

- ▶ Objetivo: Use o algoritmo k-Nearest Neighbors (k-NN) para prever se um aluno será aprovado ou reprovado com base em suas características.
- ▶ Conjunto de dados: Conjunto de dados de desempenho do aluno (curso de matemática)

Exemplo

Banco de dados

- ▶ Carregar dados: carrega o conjunto de dados de desempenho do aluno e o prepara para análise.
- ▶ Preparação de dados: cria uma variável de destino binária (passagem), seleciona recursos relevantes e normaliza os dados.
- ▶ Selecionar variáveis: "age", "Medu", "Fedu", "studytime", "failures", "absences";

```
# Load Data -----  
# Assuming the CSV file is in the working directory  
student_data <- read.csv("student-mat.csv", sep = ";")  
  
# Data Preparation -----  
# Create binary target variable 'pass'  
student_data$pass <- student_data$G3 >= 10  
  
# Select relevant features  
features <- c("age", "Medu", "Fedu", "studytime", "failures", "absences")  
student_data <- student_data %>% dplyr::select(all_of(features), pass)
```

Exemplo

Normalização

- ▶ Normalização dos dados;
- ▶ Visualização: boxplots para cada recurso para visualizar a distribuição de dados.

```
# Normalize the data
student_data_scaled <- student_data %>% dplyr::select(-pass) %>% scale()
student_data_scaled <- as.data.frame(student_data_scaled)
student_data_scaled$pass <- student_data$pass

# Visualization -----
student_data_scaled %>%
  pivot_longer(cols = -pass, names_to = "Feature", values_to = "Value") %>%
  ggplot() +
  geom_boxplot(aes(x = Feature, y = Value)) +
  theme(axis.text.x = element_text(angle = 90))
```

Exemplo

Estimaco

- ▶ Diviso Train-Test: divide os dados em conjuntos de treinamento e teste.
- ▶ Treinamento e avaliao de modelo: treina o modelo k-NN com 2 vizinhos

```
# Model Training and Evaluation -----  
# k = 2  
prediction_k2 <- FNN::knn(train = train_sample %>% dplyr::select(-pass),  
                        test = test_sample %>% dplyr::select(-pass),  
                        cl = train_sample$pass, k = 2)  
  
y_test <- test_sample$pass  
confusion_matrix_k2 <- table(y_test, prediction_k2)  
accuracy_k2 <- sum(diag(confusion_matrix_k2)) / sum(confusion_matrix_k2)  
cat(sprintf("Accuracy for k=2: %3.2f\n", accuracy_k2))
```

Exemplo

Estimaco

- Preciso de plotagem: Preciso de plotagem para k valores de 1 a 20 para ajudar a identificar o nmero ideal de vizinhos.

```
k_values <- 1:20
accuracy_values <- sapply(k_values, function(k) {
  prediction <- FNN::knn(train = train_sample[, -7],
                        test = test_sample[, -7],
                        cl = train_sample$pass, k = k)
  confusion_matrix <- table(test_sample[,7], prediction)
  accuracy <- sum(diag(confusion_matrix)) / sum(confusion_matrix)
  return(accuracy)
})

accuracy_df <- data.frame(k = k_values, accuracy = accuracy_values)

ggplot(accuracy_df, aes(x = k, y = accuracy)) +
  geom_line() +
  labs(title = "Accuracy for Different k Values", x = "k", y = "Accuracy")
```

Exemplo

Estimação




Table of Contents

Validação Cruzada

Hold-out

k-Fold

Leave-One-Out

Repeated k-Fold

Time Series

Vantagens e desvantagens

Introdução à Validação Cruzada

- ▶ Validação Cruzada (Cross-Validation, CV) é uma técnica para avaliar o desempenho de modelos de aprendizado de máquina.
- ▶ A Validação Cruzada é fácil de implementar, sendo uma ferramenta poderosa para selecionar hiperparâmetros de modelos.

Hold-out Cross-Validation

O método Hold-out é a técnica de validação cruzada mais simples e comum. Envolve dividir o conjunto de dados em duas partes: treino e teste.

▶ **Algoritmo:**

1. Divida o conjunto de dados em duas partes: conjunto de treino e conjunto de teste (Geralmente, 80% para treino e 20% para teste).
2. Treine o modelo no conjunto de treino.
3. Valide o modelo no conjunto de teste.
4. Salve o resultado da validação.

▶ **Vantagens:**

- ▶ Fácil de implementar.
- ▶ Requer treinamento do modelo apenas uma vez.

▶ **Desvantagens:**

- ▶ Pode não representar bem a distribuição de dados.
- ▶ Resultados podem ser inconsistentes devido a variações nos dados de treino e teste.

Hold-out Cross-Validation

```
# Carregar pacotes necessários
library(caret)
data(iris)

# Dividir os dados em treino (80%) e teste (20%)
set.seed(123)
trainIndex <- createDataPartition(iris$Species, p = 0.8, list = FALSE)
trainData <- iris[trainIndex, ]
testData <- iris[-trainIndex, ]

# Treinar o modelo
model <- train(Species ~ ., data = trainData, method = "knn")

# Fazer previsões no conjunto de teste
predictions <- predict(model, testData)
```

k-Fold Cross-Validation

O k-Fold Cross-Validation é uma técnica que minimiza as desvantagens do método hold-out, dividindo o conjunto de dados em k partes.

► **Algoritmo:**

1. Divida o conjunto de dados em k partes (folds) aproximadamente iguais.
2. Utilize k-1 folds para treino e 1 fold para teste.
3. Repita o processo k vezes, utilizando um fold diferente para teste a cada vez.
4. Calcule a média dos resultados de validação.

$$CV_{k\text{-Fold}} = \frac{1}{k} \sum_{i=1}^k \text{Métrica}(D_{teste}^i) \quad (52)$$

```
library(caret)
data(iris)
train_control <- trainControl(method="cv", number=10)
model <- train(Species~., data=iris, method="lm", trControl=train_control)
print(model)
```

Leave-One-Out Cross-Validation (LOOCV)

- ▶ *Leave-One-Out* Cross-Validation é um caso extremo do k-Fold, onde k é igual ao número de amostras no conjunto de dados.
- ▶ **Algoritmo:**
 1. Escolha uma amostra como conjunto de teste.
 2. Utilize as demais amostras para treino.
 3. Repita o processo para cada amostra do conjunto de dados.
 4. Calcule a média dos resultados de validação.

$$CV_{LOO} = \frac{1}{n} \sum_{i=1}^n \text{Métrica}(D_{teste}^i) \quad (53)$$

```
library(caret)
data(iris)
train_control <- trainControl(method="LOOCV")
model <- train(Species~., data=iris, method="lm", trControl=train_control)
print(model)
```

Repeated k-Fold Cross-Validation

- ▶ O Repeated k-Fold Cross-Validation é uma variação do k-Fold, onde o processo é repetido várias vezes com diferentes divisões.
- ▶ **Algoritmo:**
 1. Escolha o número de folds (k) e o número de repetições (n).
 2. Divida o conjunto de dados em k folds.
 3. Para cada repetição, utilize k-1 folds para treino e 1 fold para teste.
 4. Repita o processo k vezes em cada repetição.
 5. Calcule a média dos resultados de todas as repetições.

$$CV_{\text{Rep-k-Fold}} = \frac{1}{n \cdot k} \sum_{i=1}^n \sum_{j=1}^k \text{Métrica}(D_{\text{teste}}^{ij}) \quad (54)$$

```
library(caret)
data(iris)
train_control <- trainControl(method="repeatedcv", number=10, repeats=3)
model <- train(Species~., data=iris, method="lm", trControl=train_control)
print(model)
```

Séries Temporais

- ▶ A validação cruzada tradicional não funciona bem em dados sequenciais como séries temporais. Isso ocorre porque não faz sentido usar valores futuros para prever valores passados.
- ▶ Existem duas abordagens principais para validação cruzada em séries temporais:
- ▶ **Rolling Cross-Validation:**
 1. Comece com um pequeno subconjunto de dados para treino.
 2. Preveja os valores futuros e valide no conjunto de teste.
 3. Aumente o conjunto de treino progressivamente e repita o processo.
- ▶ **Blocked Cross-Validation:**
 1. Separe a amostra em blocos contínuos de dados.
 2. Para cada bloco divida o mesmo em conjuntos de treino e teste.
 3. Treine e valide o modelo nos blocos sequenciais.

Comparação das Técnicas de Validação Cruzada

Cada técnica de validação cruzada tem suas vantagens e desvantagens.

- ▶ **k-Fold:**

- ▶ Vantagem: Menos computacionalmente caro que LOOCV.
- ▶ Desvantagem: Pode não usar todo o conjunto de dados para treino em cada iteração.

- ▶ **LOOCV:**

- ▶ Vantagem: Usa quase todos os dados para treino.
- ▶ Desvantagem: Muito computacionalmente caro.

- ▶ **Repeated k-Fold:**

- ▶ Vantagem: Fornece uma avaliação mais robusta.
- ▶ Desvantagem: Mais caro computacionalmente que k-Fold.

Para garantir resultados confiáveis ao usar validação cruzada, considere as seguintes práticas:

- ▶ **Divisão Lógica dos Dados:** Certifique-se de que a divisão dos dados faz sentido para o problema específico.
- ▶ **Método Adequado:** Escolha o método de CV adequado para o seu conjunto de dados e problema.
- ▶ **Análise Exploratória de Dados:** Realize uma análise detalhada antes de aplicar CV.
- ▶ **Evitar Vazamento de Dados:** Em séries temporais, não valide no passado com dados do futuro.