

1 Fundamentos

Questão 1 (*Estatísticas descritivas*)

(2 pontos)

Este exercício está relacionado ao conjunto de dados **College**, que pode ser encontrado no arquivo **College.csv**. Ele contém diversas variáveis sobre 777 universidades e faculdades dos Estados Unidos. As variáveis incluídas são:

1. **Private**: Indicador se a instituição é pública ou privada
2. **Apps**: Número de aplicações recebidas
3. **Accept**: Número de candidatos aceitos
4. **Enroll**: Número de novos estudantes matriculados
5. **Top10perc**: Percentual de novos alunos vindos dos 10
6. **Top25perc**: Percentual de novos alunos vindos dos 25
7. **F.Undergrad**: Número de alunos de graduação em tempo integral
8. **P.Undergrad**: Número de alunos de graduação em tempo parcial
9. **Outstate**: Mensalidade para estudantes de fora do estado
10. **Room.Board**: Custos com moradia e alimentação
11. **Books**: Estimativa de gastos com livros
12. **Personal**: Estimativa de gastos pessoais
13. **PhD**: Percentual de docentes com doutorado
14. **Terminal**: Percentual de docentes com o grau terminal da área
15. **S.F.Ratio**: Razão aluno/docente
16. **perc.alumni**: Percentual de ex-alunos que realizam doações
17. **Expend**: Gastos com instrução por aluno
18. **Grad.Rate**: Taxa de graduação

Utilize um software de sua preferencia para fazer uma análise inicial nos dados executando as seguintes tarefas:

- (a) Gere estatísticas descritivas do banco de dados Média; Mediana; Moda; 1º e 3º Quartil; Desvio Padrão; e total de observações;
- (b) Classifique as variáveis entre: variáveis qualitativas (nominais e ordinais); variáveis quantitativas (discretas e contínuas);
- (c) Para as variáveis quantitativas, gere gráficos de dispersão para cada par de variável
- (d) Para as variáveis quantitativas, gere gráficos de caixa para cada variável.
- (e) Para a variável **Private** crie uma transformação One-To-Hot.
- (f) Gere um histograma da variável **Apps**
- (g) Aplique uma transformação logarítmica na variável **Apps** (chame essa nova variável de **ln.Apps**)
- (h) Gere um histograma da variável **ln.Apps**

2 Regressão Linear

Questão 2 (*Regressão Linear Múltipla*)

(2 pontos)

Utilizando o conjunto de dados **Auto.csv**

- (a) Produza um gráfico de dispersão para todas as variáveis no conjunto de dados.
- (b) Calcule a matriz de correlações entre as variáveis. Você precisará excluir a variável `name`, `cor()`, que é qualitativa.
- (c) Execute uma regressão linear múltipla com `mpg` como resposta e todas as outras variáveis, exceto `name`, como preditores. Comente os resultados encontrados (por exemplo: (i) Existe uma relação entre os preditores e a resposta? (ii) Quais preditores parecem ter uma relação estatisticamente significativa com a resposta? (iii) O que o coeficiente para a variável `year` sugere?
- (d) Tente algumas transformações diferentes das variáveis, como $\log(X)$, $p(X)$, X^2 . Comente sobre suas descobertas.

Questão 3 (*Boston Data*)

(2 pontos)

Utilizando o conjunto de dados **Boston.csv**, construa um modelo para prever a taxa de criminalidade per capita usando as variáveis fornecidas neste conjunto de dados.

- (a) Para cada preditor, ajuste um modelo de regressão linear simples para prever a resposta. Descreva seus resultados. Em qual dos modelos há uma associação estatisticamente significativa entre o preditor e a resposta? Crie alguns gráficos para respaldar suas afirmações.
- (b) Ajuste um modelo de regressão múltipla para prever a resposta usando todos os preditores. Descreva seus resultados. Para quais preditores podemos rejeitar a hipótese nula $H_0 : \beta_j = 0$?
- (c) Como seus resultados de (a) se comparam aos seus resultados de (b)?
- (d) Há evidência de associação não linear entre qualquer um dos preditores e a resposta? Para responder a esta pergunta, para cada preditor X , ajuste um modelo da forma $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \epsilon$.

3 Shrinkage Methods

Questão 4 (*Ridge and Lasso*)*(2 pontos)*

Construa um modelo prevendo o número de inscrições recebidas usando as outras variáveis no conjunto de dados da “College.csv”.

- (a) Divida o conjunto de dados em um conjunto de treinamento e um conjunto de teste.
- (b) Ajuste um modelo linear usando mínimos quadrados no conjunto de treinamento e relate o erro de teste obtido.
- (c) Ajuste um modelo de regressão de rígida no conjunto de treinamento, com λ escolhido por validação cruzada. Relate o erro de teste obtido.
- (d) Ajuste um modelo lasso no conjunto de treinamento, com λ escolhido por validação cruzada. Relate o erro de teste obtido, juntamente com o número de estimativas de coeficientes diferentes de zero.

4 Logit

Questão 5 (*Regressão logística*)

(2 pontos)

Utilizando os dados “Weekly.csv”

- (a) Produza alguns resumos numéricos e gráficos dos dados. Parece haver algum padrão?
- (b) Use o conjunto de dados completo para executar uma regressão logística com direção como resposta e as cinco variáveis de defasagem mais Volume como preditores. Use a função de **summary** para imprimir os resultados. Algum dos preditores é estatisticamente significativo? Se sim, qual?
- (c) Calcule a fração geral de previsões corretas.
- (d) Agora ajuste o modelo de regressão logística usando um período de dados de treinamento de 1990 a 2008, com Lag2 como o único preditor. Calcule a matriz de confusão e a fração geral de previsões corretas para os dados mantidos (ou seja, os dados de 2009 e 2010).

5 Métricas

Questão 6 (*Regressão logística*)

(2 pontos)

O conjunto de dados “Titanic.csv” contém informações sobre passageiros, incluindo recursos como ‘Pclass’, ‘Sex’, ‘Age’, ‘Fare’ e ‘Embarked’, junto com a variável de resposta binária ‘Survived’, indicando se um passageiro sobreviveu (1) ou não (0).

- (a) Carregue o conjunto de dados do Titanic de treino e de teste.
- (b) Ajuste um modelo de regressão logística aos dados de treinamento, com ‘Sobreviveu’ como a variável de resposta e os outros recursos como preditores. Discuta a significância de cada preditor com base na saída da regressão logística.
- (c) Use o modelo de regressão logística treinado para fazer previsões no conjunto de teste. Armazene essas previsões para avaliação posterior.
- (d) Crie uma matriz de confusão para as previsões no conjunto de teste. Analise a matriz e explique os tipos de erros que o modelo está cometendo (por exemplo, falsos positivos, falsos negativos). Discuta as implicações desses erros no contexto da previsão de sobrevivência no Titanic.
- (e) Calcule a precisão do modelo, que é a proporção de instâncias classificadas corretamente do total de instâncias. Discuta as limitações da precisão como uma métrica, particularmente no contexto de desequilíbrio de classe (por exemplo, mais passageiros não sobreviveram do que sobreviveram).
- (f) Calcule a precisão, recall e pontuação F1 para a classe positiva (‘Sobreviveu = 1’). Explique a importância dessas métricas, especialmente em casos em que existe desequilíbrio de classe.

6 KNN

Questão 7 (*K-vizinhos mais próximos*)

(2 pontos)

O conjunto de dados Iris, "Iris.csv", contém 150 observações de flores de íris, com quatro características (Sepal.Length, Sepal.Width, Petal.Length, Petal.Width) e uma variável de resposta categórica ('Species') com três níveis: setosa, versicolor e virginica.

- (a) gere resumos numéricos (média, mediana, intervalo, etc.) para cada uma das quatro características no conjunto de dados Iris. Preste atenção especial em como as médias e os desvios padrão diferem entre as três espécies.
- (b) Crie um boxplot para cada característica, com a espécie como variável de agrupamento. Descreva quaisquer padrões ou diferenças que você observar entre as espécies.
- (c) divida o conjunto de dados Iris em um conjunto de treinamento (70% dos dados) e um conjunto de teste (30% dos dados). Certifique-se de que os conjuntos de treinamento e teste sejam representativos das três espécies.
- (d) Use o conjunto de dados de treino para executar uma classificação KNN com 'Espécies' como resposta e as quatro características como preditores. Utilize $k = 3$, $k = 5$, $k = 7$
- (e) Compare os resultados com a base de teste e verifique qual o k ideal.

7 Cross validation

Questão 8 (*Cross validation*)

(2 pontos)

No exercício passado, usamos KNN para executar uma classificação KNN com ‘Espécies’. Vamos estimar o hiper-parâmetro K utilizando validação cruzada. Não se esqueça de definir uma semente aleatória antes de começar sua análise.

Usando a abordagem do conjunto de validação, estime o parâmetro K de KNN deste modelo. Para fazer isso, você deve executar as seguintes etapas:

- (a) Dividir o conjunto de treino em 5 conjuntos (folds).
- (b) Para cada fold, treinar um modelo KNN e determinar a acurácia de cada K em $\{1, 3, 5, 7, 9, 11, 13, 15, 17\}$
- (c) Determinar a acurácia média para cada K . Escolher o K que possui a melhor acurácia.
- (d) Estime o modelo de KNN com K escolhido na amostra de teste.