



NÚCLEO DE APOIO PEDAGÓGICO e
PESQUISA EM EDUCAÇÃO (NAPPE)

Cursos Masters

Técnicas em Machine Learning

Bruno Tebaldi Q. Barbosa

August 10, 2024

1 Aula 1 - Fundamento dos dados

1.1 Motivação

Compreender os fundamentos do aprendizado de máquina é essencial para quem deseja trabalhar com tecnologias baseadas em dados. Os dados vêm em vários formatos, e reconhecer os diferentes tipos de dados (categóricos, numéricos, de texto e séries temporais) é o primeiro passo para pré-processá-los e analisá-los de maneira eficaz. Cada tipo de dado requer diferentes técnicas de tratamento, o que impacta diretamente na escolha dos algoritmos de aprendizado de máquina. Além disso, identificar o tipo de problema (regressão, classificação, agrupamento, detecção de anomalias ou sistemas de recomendação) é crucial, pois orienta a seleção do modelo apropriado e das métricas de avaliação.

1.2 Atividade em Grupo

Você trabalha na área de modelagem de vendas de uma grande indústria têxtil. Seu objetivo é entender melhor os hábitos de consumo de jaquetas pelos clientes para melhorar as estratégias de marketing e otimizar o estoque. Recentemente, você recebeu uma base de dados contendo o número de jaquetas que cada indivíduo possui. Esta análise inicial ajudará a empresa a ter uma visão clara sobre a distribuição de posse de jaquetas entre os clientes.

Tarefas

- Calcular a Média da Amostra
- Calcular a Mediana da Amostra
- Calcular o desvio padrão da Amostra

No Jaquetas (x_i)	n_i	f_i	$x_i \times f_i$	$x_i - \bar{x}$	$(x_i - \bar{x})^2$	$(x_i - \bar{x})^2 \times f_i$
0	2					
1	7					
2	41					
3	146					
4	178					
6	108					
7	42					
8	13					
Total						

1.3 Composição dos grupos:

Os grupos devem ser constituído de 2 a 3 alunos.

1.3.1 Entrega:

A entrega deve ser um arquivo PDF ou XLSX contendo o resultado das contas.

1.4 Bibliografia

- [1] Morettin, P. A., & Bussab, W. O. (2017). **Estatística básica**. Saraiva Educação SA.
Capitulos 2 e 3

1.5 Solução esperada

No Jaquetas (x_i)	n_i	f_i	$x_i \times f_i$	$x_i - \bar{x}$	$(x_i - \bar{x})^2$	$(x_i - \bar{x})^2 \times f_i$
0	2	0.0037	0.00	-4.26	18.11	0.07
1	7	0.0130	0.01	-3.26	10.60	0.14
2	41	0.0764	0.15	-2.26	5.09	0.39
3	146	0.2719	0.82	-1.26	1.58	0.43
4	178	0.3315	1.33	-0.26	0.07	0.02
6	108	0.2011	1.21	1.74	3.04	0.61
7	42	0.0782	0.55	2.74	7.53	0.59
8	13	0.0242	0.19	3.74	14.02	0.34
Total	537		4.26			2.5848

Média: 4.26 Variância Populacional: 2.5848 Variância Amostral: 2.5896

Desvio Padrão Populacional: 1.6077 Desvio Padrão Amostral: 1.6092

1.6 Critérios de avaliação e feedback

Pontuação:

1. Planilha preenchida incorretamente: -0.5 ponto
2. Planilha parcialmente preenchida: -1 ponto
3. Planilha não preenchida: -2 ponto

Feedback:

Alunos devem receber o feedback de como abordar o preenchimento da planilha.

2 Regressão linear

2.1 Motivação

A regressão linear é uma das técnicas estatísticas e de aprendizado de máquina mais fundamentais e amplamente utilizadas. A regressão linear é simples de entender e de ser implementada. A relação entre as variáveis independentes e a variável dependente é expressa de forma clara e direta através de uma equação linear. Ela serve como uma introdução essencial para técnicas de modelagem mais complexas. Conceitos como erros de previsão, coeficientes, e métricas de desempenho são fundamentais e se aplicam a muitos outros algoritmos de aprendizado de máquina. Estudar regressão linear fornece uma base sólida para abordar problemas de modelagem e previsão, além de preparar o caminho para técnicas mais avançadas.

2.2 Atividade em Grupo

Você é um analista de dados trabalhando em um projeto para uma empresa de assentos infantis. A empresa está interessada em entender a relação entre o preço e a sua localização geográfica. Para isso, foi coletado um conjunto de dados conforme a especificação abaixo. Seu time deve: (i) Fornecer um modelo de **regressão múltipla** para prever vendas usando preço, Urbano e EUA (incluir outras variáveis se julgar necessário); (ii) Fornecer uma interpretação de cada coeficiente no modelo; (iii) Determinar se existem preditores significantes bem como explicar sobre a qualidade do modelo;

- **Sales:** Unit sales (in thousands) at each location
- **CompPrice:** Price charged by competitor at each location
- **Income:** Community income level (in thousands of dollars)
- **Advertising:** Local advertising budget for company at each location (in thousands of dollars)
- **Population:** Population size in region (in thousands)
- **Price:** Price company charges for car seats at each site
- **ShelveLoc:** A factor with levels Bad, Good and Medium indicating the quality of the shelving location for the car seats at each site
- **Age:** Average age of the local population
- **Education:** Education level at each location
- **Urban:** A factor with levels No and Yes to indicate whether the store is in an urban or rural location
- **US:** A factor with levels No and Yes to indicate whether the store is in the US or not

2.3 Composição dos grupos:

Os grupos devem ser constituído de 2 a 3 alunos.

2.4 Bibliografia

2.3.1 Entrega:

A entrega deve ser um arquivo PDF ou XLSX contendo o resultado das contas.

2.4 Bibliografia

- [1] Gareth, J., Daniela, W., Trevor, H., & Robert, T. (2013). *An introduction to statistical learning: with applications in R*. Springer.
Capitulos 2 e 3

2.5 Solução esperada

```
mdl <- lm(Sales ~ Price + CompPrice + Income + Advertising + Population +
Age + Education + Urban + US, data = tbl)
> summary(mdl)
```

Call:

```
lm(formula = Sales ~ Price + CompPrice + Income + Advertising +
    Population + Age + Education + Urban + US, data = tbl)
```

Residuals:

Min	1Q	Median	3Q	Max
-5.026	-1.341	-0.187	1.141	4.867

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	7.8243876	1.1298792	6.925	1.81e-11 ***
Price	-0.0924395	0.0050621	-18.261	< 2e-16 ***
CompPrice	0.0942545	0.0078637	11.986	< 2e-16 ***
Income	0.0130501	0.0034908	3.738	0.000213 ***
Advertising	0.1369399	0.0210394	6.509	2.33e-10 ***
Population	-0.0002007	0.0007010	-0.286	0.774780
Age	-0.0447919	0.0060226	-7.437	6.59e-13 ***
Education	-0.0423034	0.0373738	-1.132	0.258371
UrbanYes	-0.1559036	0.2133519	-0.731	0.465380
USYes	-0.1062926	0.2832192	-0.375	0.707640

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.932 on 390 degrees of freedom
Multiple R-squared: 0.5425, Adjusted R-squared: 0.5319
F-statistic: 51.38 on 9 and 390 DF, p-value: < 2.2e-16

2.6 Critérios de avaliação e feedback

Pontuação:

1. Regressão feita porem falha na interpretação: -0.5 ponto
2. Regressão feita parcialmente: -1 ponto
3. Regressão não feita: -10 pontos

Feedback:

Alunos devem receber o feedback de como realizar a regressão.

3 Regressão Lasso e Regressão Rígida

3.1 Motivação

A estimação dos mínimos quadrados ordinários sofre de problemas como multicolinearidade, que pode desestabilizar os coeficientes da regressão, bem como é sujeita ao problema de alta dimensionalidade. A Regressão Rígida e Regressão Lasso conseguem lidar com ambos os problemas visando melhorar a precisão preditiva, reduzindo o *overfitting*, alcançando um equilíbrio entre viés e variância. Ambos os métodos são capazes de lidar com cenários de dados de alta dimensão, onde os métodos tradicionais de regressão falham.

3.2 Atividade em Grupo

Na investigação educacional, compreender os factores que influenciam o desempenho dos alunos é crucial para o desenvolvimento de intervenções específicas. Ao analisar o conjunto de dados ‘student-mat.csv’, que inclui vários atributos demográficos, sociais e académicos, podemos prever as notas dos alunos usando a regressão Ridge e Lasso. Estas técnicas ajudam a gerir a multicolinearidade e a destacar os principais preditores, permitindo aos educadores identificar e apoiar os alunos em risco de mau desempenho.

Explore o conjunto de dados e determine estatísticas descritivas. Excluem-se as colunas de trabalho da mãe (Mjob), trabalho do pai (Fjob), motivo da escolha da escola (reason) e responsável pelo aluno (guardian). Além disso, exclua as séries do segundo e terceiro período (G2 e G3).

1. Transforme as variáveis categóricas restantes em formato numérico.
2. Padronize as variáveis preditoras e centralize a variável dependente (G1).
3. Estime uma **regressão Lasso**.
4. Usando validação cruzada com 10 divisões (‘nfold’), determine o melhor valor de lambda ($\lambda \in [10^{-3}, 10^4]$)
5. Para o λ ideal determine os coeficientes do modelo, a soma dos resíduos quadrados (SSR) e R2.
6. Avalie como os coeficientes se comportam com valores variados de λ

Base de dados

- **school:** Escola do aluno (código)
- **sex:** Sexo do aluno
- **age:** Idade do aluno
- **address:** Tipo de endereço residencial do aluno (‘U’: urbano; ‘R’: rural)
- **famsize:** Tamanho da família (‘LE3’: menor ou igual a 3; ‘GT3’: maior que 3)
- **Pstatus:** Situação de coabitação dos pais (binário: ‘T’ - morando junto ou ‘A’ - separado)

3.2 Atividade em Grupo

- **Medu:** Escolaridade da mãe (numérico: 0 - nenhuma, 1 - ensino fundamental, 2 - 5o ao 9o ano, 3 - ensino médio, 4 - ensino superior)
- **Fedu:** Escolaridade do pai (numérico: 0 - nenhuma, 1 - ensino fundamental, 2 - 5o ao 9o ano, 3 - ensino médio, 4 - ensino superior)
- **Mjob:** Trabalho da mãe (nominal: 'professor', 'saúde', 'serviços' (por exemplo, administrativo ou policial), 'em_casa', 'outro')
- **Fjob:** Trabalho do pai (nominal: 'professor', 'saúde', 'serviços', 'em_casa', 'outro')
- **reason:** Motivo para escolher esta escola (nominal: 'casa', 'reputação', 'curso', 'outro')
- **guardian:** responsável pelo aluno (nominal: 'mãe', 'pai', 'outro')
- **traveltime:** tempo de viagem da casa até a escola (numérico: 1 - < 15 min., 2 - 15 a 30 min., 3 - 30 min. a 1 hora, 4 - > 1 hora)
- **studytime:** tempo de estudo semanal (numérico: 1 - < 2 horas, 2 - 2 a 5 horas, 3 - 5 a 10 horas, 4 - > 10 horas)
- **failures:** Número de reprovações em classes anteriores (numérico: n se $1 \leq n < 3$, caso contrário 4)
- **schoolsup:** Apoio educacional extra (binário: sim ou não)
- **famsup:** Apoio educacional familiar (binário: sim ou não)
- **paid:** Aulas extras remuneradas dentro da disciplina do curso (Matemática ou Português) (binário: sim ou não)
- **activities:** Atividades extracurriculares (binário: sim ou não)
- **nursery:** Frequentou creche (binário: sim ou não)
- **higher:** Quer fazer ensino superior (binário: sim ou não)
- **internet:** acesso à Internet em casa (binário: sim ou não)
- **romantic:** Com um relacionamento (binário: sim ou não)
- **famrel:** Qualidade das relações familiares (numérico: de 1 - péssimo a 5 - excelente)
- **freetime:** tempo livre depois da escola (numérico: de 1 - muito baixo a 5 - muito alto)
- **goout:** Sair com amigos (numérico: de 1 - muito baixo a 5 - muito alto)
- **Dalc:** Consumo de álcool durante o dia de trabalho (numérico: de 1 - muito baixo a 5 - muito alto)
- **Walc:** Consumo de álcool no fim de semana (numérico: de 1 - muito baixo a 5 - muito alto)

3.3 Composição dos grupos:

- **saúde:** Estado de saúde atual (numérico: de 1 - muito ruim a 5 - muito bom)
- **absences:** Número de faltas escolares (numérico: de 0 a 93)
- **G1:** Nota do primeiro período (numérico: de 0 a 20)
- **G2:** Nota do segundo período (numérico: de 0 a 20)
- **G3:** Nota final (numérico: de 0 a 20)

3.3 Composição dos grupos:

Os grupos devem ser constituído de 2 a 3 alunos.

3.3.1 Entrega:

A entrega deve ser um arquivo PDF ou XLSX contendo o resultado das contas.

3.4 Bibliografia

- [1] Gareth, J., Daniela, W., Trevor, H., & Robert, T. (2013). *An introduction to statistical learning: with applications in R*. Springer.
Capitulos 6.2

3.5 Solução esperada

3.5 Solução esperada

```
# Setup -----
rm(list = ls())
library(readr)
library(dplyr)
library(glmnet)

# Data load -----
student_mat <- read_delim("../temp/Database/student-mat.csv",
                          delim = ";",
                          escape_double = FALSE,
                          trim_ws = TRUE)

# Estatística descritivas -----
str(student_mat)
summary(student_mat)

# One-to-Hot -----
for (col in colnames(student_mat)) {
  cat(sprintf("Processing: %s\n", col))
  if(!is.numeric(student_mat[[col]])) {
    cat(sprintf("Column %s is non numeric: creating factors.\n", col))
    aux <- factor(student_mat[[col]])
    if(length(levels(aux)) != 2){
      # cat(col, " has more than two levels\n" )
      cat(sprintf("%s has more than two levels. Dropping.", col), "\n" )
      student_mat[col] = NULL
    }
    else{
      student_mat[col] <- as.numeric(aux) -1
    }
    cat(sprintf("%s = 0\t%s = 1\n", levels(aux)[1], levels(aux)[2]))
  } else {
    cat("No action required.\n")
  }
  cat("\n")
}

student_mat <- student_mat %>% select(-G2,-G3)

# Padronizacao das variaveis -----
y <- student_mat %>% select(G1) %>% scale(center = TRUE, scale = FALSE) %>% as.matrix()
X <- student_mat %>% select(-G1) %>% scale() %>% as.matrix()

# Lasso Regression - cross-validation -----
lambda_to_try <- 10^seq(-3, 4, length.out = 100)
ridge_cv <- cv.glmnet(X, y, alpha = 1, lambda = lambda_to_try,
                     standardize = FALSE, nfolds = 10)

# Plot cross-validation results
plot(ridge_cv)

# Best cross-validated lambda
lambda_cv <- ridge_cv$lambda.min

# Lasso Regression - coeficientes, SSR e R2 -----
model <- glmnet(X, y, alpha = 1, lambda = 1, standardize = FALSE)

# Coeficientes do modelo
coef(model)

# Fitted values
y_hat <- predict(model, X)
SSR <- t(y - y_hat) %*% (y - y_hat)
rsq_ridge <- cor(y, y_hat)^2
cat(sprintf("SSR: %5.3f\n R2: %5.3f", SSR, rsq_ridge))

# Lasso Regression - coeficientes vs lambda -----
res <- glmnet(X, y, alpha = 1, lambda = lambda_to_try, standardize = FALSE)
plot(res, xvar = "lambda")
```

3.6 Critérios de avaliação e feedback

Pontuação:

1. Regressão feita porem falha na interpretação: -0.5 ponto
2. Regressão feita parcialmente: -1 ponto
3. Regressão não feita: -10 pontos

Feedback:

Alunos devem receber o feedback de como realizar a regressão.

4 Regressão Logística

4.1 Motivação

A regressão logística é fundamental para modelar problemas de classificação binária, oferecendo uma abordagem simples e eficaz para prever probabilidades de eventos. Sua capacidade de fornecer probabilidades interpretáveis torna-a valiosa em diversas áreas como medicina, marketing e finanças. Além disso, serve como base para técnicas mais avançadas de machine learning e é eficaz em situações com dados desbalanceados.

4.2 Atividade em Grupo

Você trabalha como analista de dados em uma empresa de marketing digital. A empresa lançou recentemente uma campanha de email marketing para promover um novo produto. Foram enviados emails para aproximadamente 30 mil clientes, e os dados coletados incluem informações demográficas dos clientes e se eles clicaram ou não no link do email para saber mais sobre o produto. Seu objetivo é determinar a probabilidade de captura do cliente, ou seja um cliente clicar no link, com base nas suas características.

Descrição da base de dados:

id	Variable Name	Description
0	resp	Response (Y=1/N=0)
1	AGE	Age of the customer
2	CRED	Credit Score
3	INCOME	Income of the customer
4	MILEAGE	Car Mileage
5	GENDER	Gender (M=1/F=0)
6	MRTGI	Mortgage Indicator (Y=1/N=0)

4.3 Composição dos grupos:

Os grupos devem ser constituído de 2 a 3 alunos.

4.3.1 Entrega:

A entrega deve ser um arquivo PDF ou XLSX contendo o resultado das contas.

4.4 Bibliografia

- [1] Gareth, J., Daniela, W., Trevor, H., & Robert, T. (2013). *An introduction to statistical learning: with applications in R*. Springer.
Capitulos 4.1; 4.2; 4.3

4.5 Solução esperada

```
> mdl <- glm(resp ~ AGE + CRED + INCOME + MILEAGE + MRTGI + GENDER,
family = binomial("logit"), data = tbl)
> summary(mdl)
```

Call:

```
glm(formula = resp ~ AGE + CRED + INCOME + MILEAGE + MRTGI +
    GENDER, family = binomial("logit"), data = tbl)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3078564	0.1496581	-8.739	< 2e-16 ***
AGE	-0.0057215	0.0013309	-4.299	1.72e-05 ***
CRED	-0.0005771	0.0002092	-2.759	0.00580 **
INCOME	-0.0091451	0.0014122	-6.476	9.44e-11 ***
MILEAGE	0.0114294	0.0034488	3.314	0.00092 ***
MRTGI	-0.3653816	0.0436342	-8.374	< 2e-16 ***
GENDER	0.1030721	0.0412641	2.498	0.01249 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 17896 on 28111 degrees of freedom
 Residual deviance: 17728 on 28105 degrees of freedom
 (1792 observations deleted due to missingness)
 AIC: 17742

Number of Fisher Scoring iterations: 5

4.6 Critérios de avaliação e feedback

Pontuação:

1. Regressão feita porem falha na interpretação: -0.5 ponto
2. Regressão feita parcialmente: -1 ponto
3. Regressão não feita: -10 pontos

Feedback:

Alunos devem receber o feedback de como realizar a regressão.

5 Avaliação de Métricas de Regressão

5.1 Motivação

As métricas de regressão são ferramentas essenciais para avaliar o desempenho de modelos preditivos. Compreender essas métricas é crucial para selecionar o modelo mais adequado e melhorar sua capacidade de previsão. Elas nos permitem quantificar o erro de previsão, a variabilidade explicada pelo modelo e a robustez das previsões. As métricas permitem comparar diferentes modelos ou identificar áreas onde o modelo precisa ser melhorado.

5.2 Atividade em Grupo

Você é um cientista de dados trabalhando para uma empresa de e-commerce que deseja prever o valor médio de compras de seus clientes com base em dados históricos de compras e características demográficas. A empresa espera usar essas previsões para personalizar ofertas e campanhas de marketing utilizando um modelo regressão linear. Para avaliar o desempenho do seu modelo de regressão, você precisa calcular várias métricas de avaliação.

As seguintes métricas para avaliar o desempenho do seu modelo de regressão:

- Erro Médio Absoluto (MAE)
- Erro Quadrático Médio (MSE)
- Raiz do Erro Quadrático Médio (RMSE)
- R-quadrado
- R-quadrado Ajustado
- Erro Percentual Absoluto Médio (MAPE)

Descrição da base de dados:

id	Variável	Descrição
1	ClienteID	Identificação única do cliente.
2	Idade	Idade do cliente.
3	RendaAnual	Renda anual do cliente.
4	ComprasAnuais	Número médio de compras anuais.
5	ValorTotalCompras	Valor total das compras no último ano.

5.3 Composição dos grupos:

Os grupos devem ser constituído de 2 a 3 alunos.

5.3.1 Entrega:

A entrega deve ser um arquivo PDF ou XLSX contendo o resultado das contas.

5.4 Bibliografia

- [1] Gareth, J., Daniela, W., Trevor, H., & Robert, T. (2013). *An introduction to statistical learning: with applications in R*. Springer.
Capitulos 2.2; 9.6.3

5.5 Solução esperada

```
# Setup -----
rm(list = ls())

library(readr)
library(dplyr)
library(glmnet)

# Data Load -----
data <- read.csv('./database/WB5 - Meticas - dados_compras.csv')

set.seed(12345)

trainIndex <- sample(1:nrow(data), size = floor(0.8*nrow(data)))
trainData <- data[trainIndex,]
testData <- data[-trainIndex,]

# Treinar o modelo de regressão linear
modelo <- lm(valor_total_compras ~ idade + renda_anual +
  compras_anuais, data = trainData)
summary(modelo)

# Fazer previsões
# previsoos <- predict(modelo, newdata = testData, type = "response")
previsoos <- predict(modelo, newdata = testData)

# Valores reais
valores_reais <- testData$valor_total_compras

# Calcular métricas
mae <- mean(abs(valores_reais - previsoos))
mse <- mean((valores_reais - previsoos)^2)
rmse <- sqrt(mse)
r_squared <- summary(modelo)$r.squared
adjusted_r_squared <- summary(modelo)$adj.r.squared
mape <- mean(abs((valores_reais - previsoos) / valores_reais)) * 100

resp = c("MAE" = mae, "MSE" = mse, "RMSE" = rmse, "R2" = r_squared,
  "R2 Ajus." = adjusted_r_squared, "MAPE" = mape)

# Imprimir métricas
cat("\n", sprintf("%8s: %10.4f\n", names(resp), resp))
# MAE:      797.3787
# MSE: 1031878.0472
# RMSE:  1015.8140
# R2:       0.9012
# R2 Ajus.:    0.9009
# MAPE:       3.2322
```

5.6 Critérios de avaliação e feedback

Pontuação:

1. Regressão feita porem falha na interpretação: -0.5 ponto
2. Regressão feita parcialmente: -1 ponto
3. Regressão não feita: -10 pontos

Feedback:

Alunos devem receber o feedback de como realizar a regressão.

6 K-Nearest Neighbors

6.1 Motivação

O algoritmo K-Nearest Neighbors (KNN) é um dos algoritmos de aprendizado supervisionado mais simples e eficazes. Ele é amplamente utilizado em problemas de classificação e regressão devido à sua simplicidade e eficácia em diversas aplicações práticas. O KNN funciona identificando os 'k' pontos de dados mais próximos de um ponto de interesse e, em seguida, atribuindo a classe mais comum (no caso de classificação) ou a média dos valores (no caso de regressão).

6.2 Atividade em Grupo

Você é um cientista de dados contratado para classificar espécies de flores com base no famoso conjunto de dados Iris. Seu objetivo é utilizar o algoritmo KNN para prever a espécie de uma flor com base em suas características medidas (comprimento e largura das sépalas e pétalas). Você precisa dividir o conjunto de dados em conjuntos de treino e teste, treinar o modelo KNN, fazer previsões e avaliar o desempenho do modelo usando uma matriz de confusão e a taxa de acerto.

Tarefas

1. **Carregar o Conjunto de Dados:** Carregue o conjunto de dados 'iris'.
2. **Pré-processamento:** Escale as variáveis numéricas para que todas estejam na mesma escala.
3. Divida os dados em conjuntos de treino e teste (50/50).
4. **Treinamento do Modelo KNN:** Utilize o algoritmo KNN para prever a espécie das flores no conjunto de teste com $k=3$.
5. **Avaliação do Modelo:** Calcule a matriz de confusão e a taxa de acerto para $k=3$.
6. **Análise de Sensibilidade:** Plote a taxa de acerto para diferentes valores de k e determine o valor ótimo de k .

6.3 Composição dos grupos:

Os grupos devem ser constituído de 2 a 3 alunos.

6.3.1 Entrega:

A entrega deve ser um arquivo PDF ou XLSX contendo o resultado das contas.

6.4 Bibliografia

- [1] Gareth, J., Daniela, W., Trevor, H., & Robert, T. (2013). *An introduction to statistical learning: with applications in R*. Springer.
Capítulo 4.7.6

6.5 Solução esperada

```
# Setup -----
# Clear all
rm(list = ls())

# libraries
library(ggplot2)
library(dplyr)
library(tidyr)
library(FNN)

# Load Data -----
tbl <- read.csv("./database/WB6 - KNN Iris.csv")

# Data Preparation -----
boxplot(tbl[, -5])

# Normalize the data
tbl_data_scaled <- tbl[, -5] %>% scale() %>% as.data.frame()
tbl_data_scaled$Species <- tbl[,5]

# Visualization -----
boxplot(tbl_data_scaled[, -5])

# Train-Test Split -----
set.seed(42) # For reproducibility

n <- nrow(tbl_data_scaled)
train_idx <- sample(1:n, n / 2, replace = FALSE)
train_sample <- tbl_data_scaled[train_idx, ]
test_sample <- tbl_data_scaled[-train_idx, ]

# Model Training and Evaluation -----
# k = 3
prediction_k3 <- FNN::knn(train = train_sample[, -5],
                        test = test_sample[, -5],
                        cl = train_sample[, 5], k = 3)

y_test <- test_sample$Species
confusion_matrix_k3 <- table(y_test, prediction_k3)
accuracy_k3 <- sum(diag(confusion_matrix_k3)) / sum(confusion_matrix_k3)
cat(sprintf("Accuracy for k=2: %.2f\n", accuracy_k3))

# Plotting accuracy for different k values -----
k_values <- 1:20
accuracy_values <- sapply(k_values, function(k) {
  prediction <- FNN::knn(train = train_sample[, -5],
                        test = test_sample[, -5],
```

```

        cl = train_sample[, 5], k = k)
confusion_matrix <- table(test_sample[,5], prediction)
accuracy <- sum(diag(confusion_matrix)) / sum(confusion_matrix)
return(accuracy)
})

accuracy_df <- data.frame(k = k_values, accuracy = accuracy_values)

ggplot(accuracy_df, aes(x = k, y = accuracy)) +
  geom_line() +
  labs(title = "Accuracy for Different k Values", x = "k", y = "Accuracy")

```

6.6 Critérios de avaliação e feedback

Pontuação:

1. Regressão feita porem falha na interpretação: -0.5 ponto
2. Regressão feita parcialmente: -1 ponto
3. Regressão não feita: -10 pontos

Feedback:

Alunos devem receber o feedback de como realizar a regressão.

7 Validação Cruzada

7.1 Motivação

A validação cruzada é uma técnica essencial para avaliar o desempenho de modelos de aprendizado de máquina. Ela nos permite medir a capacidade do modelo de generalizar para novos dados, evitando o problema de *overfitting* (quando o modelo se ajusta excessivamente aos dados de treino) e *underfitting* (quando o modelo é muito simples e não captura a complexidade dos dados). Usar validação cruzada garante que a avaliação do modelo seja robusta e confiável, fornecendo uma estimativa precisa de sua performance em dados não vistos.

7.2 Atividade em Grupo

Você trabalha como cientista de dados em uma empresa de tecnologia que desenvolve soluções de previsão de preços de imóveis. Você precisa construir um modelo de regressão para prever o preço de casas com base em suas características. Para garantir que o modelo seja robusto e tenha um bom desempenho em novos dados, você decide usar validação cruzada para avaliar diferentes modelos.

Tarefas

1. **Análise Exploratória de Dados:** Realize uma análise descritiva das variáveis.
2. **Pré-processamento:** Trate valores ausentes e variáveis categóricas.
3. **Implementação de Validação Cruzada:** Estime um modelo de regressão linear onde **price** é a variável dependente e as colunas **beds**, **baths**, **sqft**, **type** são as variáveis independentes.
 - Utilize a técnica de k-Fold Cross-Validation para avaliar um modelo de regressão linear.
 - Utilize a técnica de Repeated k-Fold Cross-Validation para avaliar o mesmo modelo.
 - Utilize a técnica de Leave-One-Out Cross-Validation para avaliar o mesmo modelo.

7.3 Composição dos grupos:

Os grupos devem ser constituído de 2 a 3 alunos.

7.3.1 Entrega:

A entrega deve ser um arquivo PDF ou XLSX contendo o resultado das contas.

7.4 Bibliografia

- [1] Gareth, J., Daniela, W., Trevor, H., & Robert, T. (2013). *An introduction to statistical learning: with applications in R*. Springer.
Capítulos 5.1

7.5 Solução esperada

```
# Setup -----
# Clear all
rm(list = ls())

# Libraries
library(caret)
library(dplyr)

# Load Data -----
Sacramento <- read.csv("./Sacramento.csv")

# Análise Exploratória de Dados -----
head(Sacramento)
summary(Sacramento)

# Pré-processamento -----

# Tratar valores ausentes e variáveis categóricas
housing_data <- Sacramento %>%
  mutate_if(is.character, factor) %>%
  na.omit()

# Implementação de Validação Cruzada -----
# k-Fold Cross-Validation
set.seed(123)
train_control_kfold <- trainControl(method = "cv", number = 10)
model_kfold <- train(price ~ beds + baths + sqft + type,
  data = housing_data, method = "lm",
  trControl = train_control_kfold)
print(model_kfold)
summary(model_kfold)

# Repeated k-Fold Cross-Validation
set.seed(123)
train_control_repeated <- trainControl(method = "repeatedcv",
  number = 10, repeats = 3)
model_repeated <- train(price ~ beds + baths + sqft + type,
  data = housing_data, method = "lm",
  trControl = train_control_repeated)
print(model_repeated)
summary(model_repeated)

# Leave-One-Out Cross-Validation
set.seed(123)
train_control_loocv <- trainControl(method = "LOOCV")
model_loocv <- train(price ~ beds + baths + sqft + type,
  data = housing_data, method = "lm",
  trControl = train_control_loocv)
```

```
print(model_loocv)
summary(model_loocv)
```

7.6 Critérios de avaliação e feedback

Pontuação:

1. Regressão feita porem falha na interpretação: -0.5 ponto
2. Regressão feita parcialmente: -1 ponto
3. Regressão não feita: -10 pontos

Feedback:

Alunos devem receber o feedback de como realizar a regressão.