

1 Intordução

Você acabou de ser contratado como Analista de Dados no **Howell Bank & Trust**. Seu departamento, liderado por Clara Barker, é responsável por relatórios e criação de modelos que ajudarão os gerentes do banco nas tarefas diárias.

No seu primeiro dia, Barker (chefe do departamento) entrega um arquivo para você e diz: “Precisamos reduzir as perdas potenciais nos empréstimos.”

Já que este é seu primeiro dia, você pergunta: “O que você quer dizer?”

Barker explica que, quando um banco recebe um pedido de empréstimo, com base no perfil do solicitante, o banco deve tomar uma decisão sobre a aprovação ou não do empréstimo. Dito isto, existem dois tipos de riscos associados à decisão do banco:

- Se o requerente é um bom risco de crédito, ou seja, é provável que pague o empréstimo, então não aprovar o empréstimo para a pessoa resulta em perda de negócios para o banco
- Se o requerente for um risco de crédito ruim, ou seja, provavelmente não pagará o empréstimo, a aprovação do empréstimo à pessoa resultará em uma perda financeira para o banco

Matheus Cooper, o analista sênior do departamento, está a frente do projeto e lhe passa uma lista de tarefas que devem ser executadas.

2 Objetivo

Avaliar a performance preditiva dos modelos utilizados pelo departamento. A avaliação deve ser feita pela métrica de acurácia (ACC).

$$ACC = \frac{TP + TN}{TP + TF + FP + FN} \quad (1)$$

onde TP é o total de acertos positivos (“true positive”); TN é o total de acertos negativos (“true negative”); FP é o total de erros positivos (“false positive”); FN é o total de erros negativos (“false negative”);

3 Anotações de Cooper

- Análises iniciais indicam que as maiores taxas de conversão são verificadas no grupo de estudantes e de aposentados. Em compensação a taxa de conversão não parece depender do estado civil. por favor faça as análises abaixo para confirmar minhas suspeitas.
- Os campos `contact`, `month`, `day_of_week`, `duration`, são relacionados com o último contacto da campanha atual. No entanto, a duração não é conhecida antes de uma chamada ser realizada. Além disso, após o final da

chamada, y (a variável de observação) é obviamente conhecido. Assim essas variáveis serão descartadas para se ter um modelo preditivo realista. Vale salientar que estamos ignorando um possível efeito calendário.

- Note que temos pouca variação nas variáveis “pdays” e “duration”. Sendo assim elas não serão utilizadas. Portanto assim elimine do banco de dados as colunas: contact, month, day_of_week, duration, pdays. (Dica: no R para eliminar uma coluna jogue o valor da coluna para NULL)

4 Lista de tarefas

1. Carregue o banco de dados “bank-additional-full.csv”
2. Classifique as variáveis entre variáveis qualitativas e quantitativas.
3. Verifique se o banco de dados esta completo ou se existem dados faltantes. (caso existam elimine essas observações).
4. Calcule a taxa de conversao da atual campanha. (quantidade de registros com $y=1$, sobre o total de registros)
5. Faça as estatísticas descritivas das variáveis quantitativas. Faça também um boxplot das variáveis quantitativas.
6. Para a variável de idade faça um histograma das mesma.
7. Agrupe os clientes em sete classes distintas: $(15 - 20]$, $(20 - 30]$, $(30 - 40]$, $(40 - 50]$, $(50 - 60]$, $(60 - 70]$, $(70, \infty)$
8. Faça um gráfico de barras com a taxa de conversão por faixa etária.
9. Faça um gráfico de barras com a taxa de conversão por estado civil.
10. Faça um gráfico de barras com a taxa de conversão por profissão.
11. Faça um gráfico de barras com a taxa de conversão por educação.
12. Faça um gráfico de barras com a taxa de conversão por empréstimo (loan).
13. Faça um gráfico de barras com a taxa de conversão por proprietário de imóvel (housing).
14. Utilize a transformação de **normalização** para as variáveis quantitativas: age, campaign, previous, emp.var.rate, cons.price.idx, cons.conf.idx, euribor3m, nr.employed.
15. Faça a transformação one-to-hot para as variáveis qualitativas: job, marital, education, housing, loan, poutcome.
16. Note: lembre-se que temos de transformar a variável resposta (y) em uma **variável binária**.

17. Separe a amostra em Treinamento e Teste. Note que a amostra devera ser balanceada para compensar a grande quantidade de resultados negativos.
 - Para a amostra de **teste**, selecione 1800 elementos (900 elementos com $y=1$ e 900 elementos com $y=0$) de forma aleatória.
 - Para a amostra de **treino** selecione todo o restante dos elementos com resultado positivo (3740 elementos com $y=1$) e uma amostra de mesmo tamanho com resultado negativo (3740 elementos com $y=0$).
18. Construa os seguintes modelos:
 - KNN com 7, 15, e 21 vizinhos;
 - Modelo Logit
19. Utilizando os modelos acima construa a matriz de confusão de cada modelo e calcule a **acurácia** de cada modelo na amostra de teste.

5 Entrega

A entrega deve ser uma apresentação contendo:

- **(obrigatório)** As imagens requeridas;
- **(obrigatório)** A matriz de confusão de cada modelo;
- **(obrigatório)** A acurácia de cada modelo;
- (opcional) Lista de dificuldades encontradas;
- (opcional) Lista de possíveis melhorias;

Table 1: Descrição do Banco de Dados

ID	Variável	Descrição
1	age	Idade
2	job	tipo de trabalho (categórico)
3	marital	estado civil (categórico)
4	education	educação (categórico)
5	default	tem crédito em atraso? (categórico)
6	housing	tem crédito à habitação? (categórico)
7	loan	tem empréstimo pessoal? (categórico)
8	contact	tipo de comunicação do contato (categórico)
9	month	mês do último contato do ano (categórico)
10	day_of_week	último dia de contato da semana (categórico)
11	duration	duração do último contato, em segundos
12	campaign	número de contatos realizados durante esta campanha
13	pdays	número de dias que se passaram desde o último contato com o cliente
14	previous	número de contatos realizados antes desta campanha
15	poutcome	resultado da campanha de marketing anterior (categórico)
16	emp.var.rate	taxa de variação do emprego - indicador trimestral
17	cons.price.idx	índice de preços ao consumidor - indicador mensal
18	cons.conf.idx	índice de confiança do consumidor - indicador mensal
19	euribor3m	taxa euribor a 3 meses - indicador diário
20	nr.employed	número de funcionários - indicador trimestral
21	y	o cliente subscreveu um depósito a prazo? (categórico: 'yes', 'no')